

# 利用深度强化学习的综合未知环境下自主移动机器人的路径规划

白泽坤、庞辉、*Member, IEEE*、何兆年、赵斌、王童

**Abstract**——在现实场景中，未知环境下的自主移动机器人（AMR）的路径规划往往会遇到一些不可避免的问题，如对环境信息的严重依赖、推理时间长、抗干扰能力弱等。为了解决这些问题，本文提出了一种改进的基于深度强化学习的路径规划算法，以找出一类 AMR 的优化路径。首先，将 AMR 的路径规划描述为马尔可夫决策过程框架，并利用双深度  $Q$  网络（DDQN）来获得 AMR 路径规划的最优自适应解。其次，设计与启发式功能相结合的综合奖励功能，以将 AMR 引导到目标区域。随后，设计了具有自适应  $\epsilon$ -贪婪动作选择策略的优化深度神经网络来处理探索和利用之间的权衡，从而进一步提高 AMR 路径规划的全局搜索能力和收敛性能。此外，利用贝塞尔曲线理论来平滑规划路径。最后，进行比较模拟以验证我们提出的路径规划算法。结果表明，与 DQN、A\*、RRT 和 APF 算法相比，我们改进的 DDQN 算法可以在全面的未知环境中产生更安全、更短的全局路径。同时，IDDQN 算法对未知环境中的随机扰动具有很强的适应性。

**Index Terms**——自主移动机器人（AMR）、深度强化学习（DRL）、双深度  $Q$  网络（DDQN）、路径规划、路径平滑。

## 一、简介

近年来，自主移动机器人（AMR）以其体积小、部署灵活、独立完成任务等优点，在生物医学、太空探索、工程设备检修与维护等领域获得了广泛的应用前景[1]。路径规划是 AMR 领域的核心功能之一。因此，提高 AMR 的自主路径规划能力对于研究人员来说显得尤为重要。路径规划系统需要生成一条可行路径，同时

满足多重约束：如与障碍物保持安全距离、到目标的最短距离、路径平滑度和环境干扰信息[2]、[3]。在未知环境中执行任务时，AMR 应根据从周围环境收集的信息计算并修改其可行的无碰撞路径 [4]。此外，AMR 需要在存在外部环境因素潜在干扰的情况下生成符合约束的路径导航信息。因此，具有高度自主性和学习能力的路径规划方法对于 AMR 来说至关重要。

机器人系统的路径规划算法已经得到了大量的研究成果，大致可分为三类：1) 传统算法；2) 仿生算法；3) 基于学习的算法，如图1所示。传统算法包括基于图、基于采样和基于数据的方法。仿生算法包括遗传算法、人工群体算法、模糊逻辑算法等。基于学习的算法包括深度强化学习（DRL）算法和元学习等。具体来说，常用的传统方法包括 A 星算法（A\*）[5]、人工势场算法（APF）[6] 和快速探索随机树算法（RRT）[7]。A\* 算法虽然可以有效地确定最短路径，但其计算量会随着空间的扩展呈指数增长，因此不适合复杂的连续障碍物环境[8]。APF 算法采用势函数下降法来识别理想路径[9]。林等人。[10] 设计了一种两级路径规划方法，采用改进的 APF 算法和动态窗口算法来引导机器人避开障碍物，合理规划更短、更平滑的路径。然而，随着障碍物数量的增加，APF 算法会遇到环境中越来越多的零势能点，很容易陷入局部极小点而无法规划出完整的路径。RRT 算法是一种基于随机采样的路径规划算法，虽然 RRT 算法具有较强的搜索能力和较快的搜索速度，但也存在搜索精度低、路径平滑性差等局限性[11]。仿生算法利用生物结构的行为来寻找优化路径[12]。典型的算法包括遗传算法[13]、蚁群优化[14]等。与传统算法相比，仿生算法计算量少，具有

Manuscript received 29 January 2024; revised 10 March 2024; accepted 14 March 2024. Date of publication 19 March 2024; date of current version 7 June 2024. This work was supported in part by the National Natural Science Foundation of China under Grant 51675423, and in part by the Natural Science Foundation (Key Project) of Shaanxi Province, China, under Grant 2023-JCZD-31. (Corresponding author: Hui Pang.)

The authors are with the School of Mechanical and Precision Instrument Engineering, Xi'an University of Technology, Xi'an 710048, China (e-mail: panghui@xaut.edu.cn).

Digital Object Identifier 10.1109/IJOT.2024.3379361

2327-4662 © 2024 IEEE. Personal use is permitted, but republication/redistribution requires IEEE permission.

See <https://www.ieee.org/publications/rights/index.html> for more information.

Authorized licensed use limited to: Tsinghua University. Downloaded on December 16, 2025 at 12:31:18 UTC from IEEE Xplore. Restrictions apply.




图 1 路径规划算法分类图。

应对复杂环境优势明显。但它们仍然存在一些不足，如对环境的依赖性强、容易陷入局部最优等。

因此，传统方法和仿生算法在没有全局先验环境信息的情况下很难解决路径规划问题，并且缺乏对系统扰动等不确定性的适应性。为了在未知环境中实现路径规划，一些研究人员开始开发更智能的路径规划方法，使AMR能够在实践中自行学习。机器学习（ML）是发展最快的人工智能算法之一，旨在通过学习历史经验数据来自动改进系统策略[15]。刘等人。[16]设计了一种微型机器学习算法来协助无人机互联网在飞行过程中做出实时决策，最终产生高效且安全的飞行路径。因此，将机器学习方法应用于机器人导航领域可以使机器人学习环境信息并自主完成路径规划任务。

强化学习（RL）作为机器学习的一个分支，可以通过与外部环境交互并从外部环境获取反馈信息来学习和调整学习策略，并且RL在克服对环境信息的依赖方面显示出巨大的潜力[17]，[18]。在[19]中， $Q$ -学习算法被用来处理未知环境下自主水下航行器的避障和路径规划问题。鉴于强化学习算法在未知环境下具有更好的路径规划能力，一些研究已成功地将强化学习应用于移动机器人系统中。例如，[20]提出了一种将 $Q$ -Learning与FPA相结合的算法，并将其应用于AMR的路径规划，解决了传统 $Q$ -Learning算法收敛速度慢的问题。在[21]中，它将启发式搜索策略和模拟退火机制纳入基于Dyna架构的 $Q$ -Learning中，增强了移动机器人路径规划的全局搜索性能和学习效率。尽管如此， $Q$ -学习算法通过建立 $Q$ -值表来存储环境中的所有状态值，并通过查询访问这些信息。随着环境和动作维度的增加， $Q$ -学习算法需要大量的计算资源，这降低了学习效率并可能阻碍算法收敛[22]。

DRL集成了RL的决策能力和深度学习（DL）的感知能力，可以弥合高维输入和行动之间的差距。近年来，DRL已广泛应用于无人机、自主水下航行器和无人水面航行器路径规划的控制[23]、[24]、[25]、[26]以及自动驾驶[27]。此外，学术界还提出了几种基于DRL的AMR路径规划算法；这些算法本质上基于深度 $Q$ 网络（DQN）及其相关算法。具体来说，Wen等人。[28]提出了一种基于神经网络强化学习路径系统的新型路径规划方法，使移动机器人能够在不与任何障碍物或机器人碰撞的情况下导航到终端区域，并且该方法已经成功应用于移动机器人实验平台。吴等人。[29]提出了一种用于移动机器人自主转向的改进的双DQN（DDQN）算法，并验证了其在各种类型的现实障碍环境中的性能。王等人。[30]提出了一种基于HFG-DRL的新型自由步态多接触路径规划方法，训练后的路径规划策略可以使机器人在非结构化环境中自动调整步态模式，快速平稳地到达目标区域。Tai和Hafid[31]提出了一种基于DDQN-PER算法的深度感知框架来解决深度感知任务分配问题，从而为移动用户规划更有效的行进路径并实现特定目标。江等人。文献[32]提出了一种改进的DQN算法来解决地形复杂的小行星表面跳跃漫游器的路径规划问题，并证明该路径规划算法在随机变化的地形下具有一定的适应性。然而，直接将DQN算法应用于路径规划会带来几个固有的问题：1）随着环境模型复杂度的增加，DQN的学习效率会变差，收敛速度会降低；2）传统DQN算法规划的路径往往安全性较差，AMR存在碰撞障碍物边缘的风险；3）传统DQN算法规划的路径轨迹往往存在冗余且缺乏平滑性。

受前面讨论的启发，本研究提出了一种改进的基于双DQN（IDDQN）的AMR算法，用于在具有随机障碍物的全面未知环境中执行路径规划任务。本文的主要贡献总结如下。

- 1) 设计了一种新型的综合奖励函数，使AMR在综合未知环境中快速、安全地逼近目标区域。
- 2) 自适应 $\epsilon$ -贪婪行动策略旨在解决探索和利用之间的权衡。该策略可以通过结合优化的深度神经网络（DNN）来提高AMR路径规划的学习效率和收敛率。
- 3) 多次仿真实验结果表明，所提出的IDDQN算法在解决AMR路径规划问题上比传统方法表现出更好的性能。IDDQN的稳健性




图2.AMR路径规划示意图。

算法还在具有随机干扰的未知环境中得到验证。

本文的其余部分安排如下。第二节描述了AMR的路径规划问题,并介绍了马尔可夫决策过程(MDP)和DDQN算法。第三节介绍了AMR路径规划的MDP模型和基于IDDQN的AMR路径规划算法模型。第四节介绍了不同路径规划算法的仿真对比实验分析,并验证了IDDQN算法在干扰环境中的鲁棒性。结论和未来的工作在第五节中介绍。

## 二. AMR 路径规划的基本理论

AMR路径规划如图2所示,是指AMR考虑所有外部环境信息和多重约束,自动生成从起点(SP)到目标点(TP)的平滑且无碰撞的最优路径(绿色轨迹线)的完整过程[33]。

根据相关文献[34]、[35],AMR的路径规划可以看作是MDP框架中的学习过程。其中,AMR采取行动与外部环境交互,改变自身状态以获得奖励;同时,AMR的目标是学习获得最大累积奖励的行动策略,最终生成所需的路径轨迹。基于上述描述,首先介绍MDP理论和DDQN算法的知识。

### A. Markov Decision Processes

MDP可以表示为五元组  $M = [S, A, P, R]$ , 其中  $S$  表示环境中存在的有限状态集,  $s_t$  表示时间  $t$  的状态,  $A$  表示代理执行的动作 (AMR),  $a_t$  表示时间  $t$  执行的动作,  $P$  是转移概率,  $R$  是奖励函数。根据观察到的环境状态  $s_t$ , AMR 随机选择并执行动作  $a_t$ 。随后,环境为 AMR 提供奖励  $r_{t+1}$ , 同时将状态从  $s_t$  更新到下一个状态  $s_{t+1}$ 。MDP 框架中的 AMR-环境交互如图3所示。




图3. MDP 框架中的 AMR-环境交互。

具体来说,在时间  $t$ ,当 AMR 在状态  $a \in A$  下执行操作  $s \in S$  时,  $s'$  可以由下式给出

$$P(s, a, s') = P(s' | s, a) = \text{prob}[s_{t+1} = s' | S_t = s, A_t = a]. \quad (1)$$

在整个学习过程中,AMR旨在学习与最大化长期累积奖励相对应的最优策略。然后,AMR可以在探索过程中获得最大的长期累积奖励  $R_t$ 。  $R_t$  可以由下式给出

$$R_t = r_{t+1} + \gamma r_{t+2} + \gamma^2 r_{t+3} + \dots = \sum_{k=0}^{\infty} \gamma^k r_{t+k+1} \quad (2)$$

其中  $r_t$  表示 AMR 在时间  $t$  的奖励。  $\gamma$  是折扣率 ( $\gamma \in [0, 1]$ ),  $\gamma$  决定未来的回报值。

为了获得当前行动和未来奖励之间的长期关系,使用最优策略  $\pi$  下的总潜在奖励来制定行动价值函数  $Q_{\pi}(s, a)$ , 其可以表示为

$$Q_{\pi}(s, a) = E_{\pi}[R_t | S_t = s, A_t = a] = E_{\pi} \left[ \sum_{k=0}^{\infty} \gamma^k r_{t+k+1} | s_t, a_t \right] \quad (3)$$

其中  $E_{\pi}$  表示随机变量在概率分布  $\pi$  下的数学期望。

### B. Double Deep Q Network

在本节中,DQN算法用于解决AMR路径规划决策问题。DQN作为DRL中的一种重要算法,有效地结合了Q学习和神经网络技术,从高维复杂的状态空间中获取最优控制策略,而不依赖于环境的先验信息[36]。因此,利用DQN使AMR能够在外部环境信息不完整的复杂障碍物环境中生成最佳路径。

DQN 算法采用神经网络来逼近  $Q$  值函数,如(3)所示。DQN 算法的整体学习架构如图4所示。值得注意的是,目标网络和




图4. 总体 DQN 架构。

经验重播机制显著提高了训练的准确性和稳定性[37]。在训练过程中，当前网络通过与环境交互学习，生成经验数据（当前状态 $s$ 、动作 $a$ 、奖励 $r$ 、下一个状态 $s'$ ），并存储在一定容量的经验回放池中（如果存储满了，则从第一组开始依次覆盖原有经验）。根据当前网络获得的经验数据，不断更新和优化目标网络的参数，最终得到最大的动作策略。获得奖励。

当前网络和目标网络的区别在于如何选择输入向量和网络更新周期。具体来说，当前网络将当前状态 $s$ 作为输入，并在每次迭代时更新它；目标网络将下一个状态 $s'$ 作为输入，并定期将当前网络的参数复制到目标网络。在每个训练步骤中，采用时间序列差分法计算目标网络对应的目标 $Q$ -值( $Q_{\text{Target}}^{\text{DQN}}$ )，可以表示为

$$Q_{\text{Target}}^{\text{DQN}} = r + \gamma \max_{a'} Q(s', a'; \theta^-) \quad (4)$$

其中 $\max_{a'} Q(s', a'; \theta^-)$ 是目标网络输出的最大 $Q$ 值， $a'$ 是AMR在状态 $s'$ 下采取的动作， $\theta^-$ 表示目标网络的权重参数。

当前网络预测的 $Q$ 值与目标网络预测的 $Q$ 值之间的均方偏差定义为损失函数 $L(\theta)$ ，其形式为

$$L(\theta) = E \left[ \left( Q_{\text{Target}}^{\text{DQN}} - Q(s, a; \theta) \right)^2 \right] \quad (5)$$

其中 $Q(s, a; \theta)$ 表示当前网络的输出， $\theta$ 表示当前网络的权重参数。

通过将目标 $Q$ -值( $Q_{\text{Target}}^{\text{DQN}}$ )的计算与DQN算法中动作的选择解耦，DDQN算法可以进一步消除可能的高估问题并生成更可靠和稳定的学习过程[38]。

DDQN 不是直接从目标网络获取最大  $Q$  值，而是首先根据当前网络查找最大  $Q$  值。然后，使用以下公式计算对应于该动作的目标 $Q$ 值( $Q_{\text{Target}}^{\text{DDQN}}$ )




图5. 环境模型示例（左：3-D 环境，右：2-D 网格环境）。

具有参数 $\theta^-$ 的目标网络，如(6)所示，并且所选动作被评估为

$$Q_{\text{Target}}^{\text{DDQN}} = r + \gamma Q'(s', \arg\max_{a'} Q(s', a; \theta); \theta^-) \quad (6)$$

其中 $\arg\max_{a'} Q(s', a; \theta)$ 是目标网络的最大输出 $Q$ 值对应的动作，当前网络的预测值为 $Q'(s', \arg\max_{a'} Q(s', a; \theta); \theta^-)$ 。

### 三. 路径规划综合

在本节中，AMR路径规划问题首先被重新表述为MDP模型，其中MDP主要包含状态空间、动作空间和奖励函数。然后，提出一种改进的DDQN算法，求解AMR路径规划的MDP模型，并通过路径平滑方法获得最优路径。

#### A. MDP of AMR Path Planning

1) *State Space*: 基于网格的度量模型主要用于建立环境地图[39], [40]。这里，将3D环境的特征信息映射到等尺寸的2D网格中，如图5所示，使得AMR能够在30m\*30m的2D网格环境中进行路径规划。根据环境中障碍物的分布情况，障碍物用黑色网格表示，AMR的自由运动区域（智能体的可行状态）用白色网格表示，每个网格的宽度为1 m。为了便于构建模拟环境地图，未完全占据网格的障碍物将被视为完整的障碍物网格。

由于计算路径长度时要考虑AMR与目标之间的欧氏距离 $TD_i (i = 1, 2, \dots, t)$ ，因此将AMR和 $TD_i$ 的位置坐标 $(x, y)$ 引入状态空间。此外，由于避障对于路径规划和评估运动安全至关重要，因此AMR与传感器识别的障碍物之间的欧氏距离定义为 $OD_i (i = 1, 2, \dots, t)$ ，如图6所示。 $TD_i$ 和 $OD_i$ 都表示在时间 $t$ 时AMR周围一定距离内可获得的当前环境信息。国家




图 6. 状态空间。




图 7. AMR 操作空间。

AMR的空间方程可表示为

$$S = \begin{bmatrix} x_1 & y_1 & TD_1 & OD_1 \\ x_2 & y_2 & TD_2 & OD_2 \\ \vdots & \vdots & \vdots & \vdots \\ x_t & y_t & TD_t & OD_t \end{bmatrix}_{t \times 4} \quad (7)$$

2) *Action Space*: 通常, AMR的运动状态包括启动、停止、直线运动和转向, 这些状态由伺服电机控制, 并且在路径规划过程中假设AMR的速度保持恒定。为了简化AMR的运动模型, AMR的动作空间可以描述为8个动作, 即 $A = \{\text{上、下、左、右、右上、右下、左上、左下}\}$ , 具体动作空间如图7所示。

基于此, AMR在网格环境下的传输规则可以表示为

$$\begin{cases} (x', y') = (x + \text{grid}, y) \\ (x', y') = (x, y + \text{grid}) \\ (x', y') = (x - \text{grid}, y) \\ (x', y') = (x, y - \text{grid}) \\ (x', y') = (x + \text{grid}, y + \text{grid}) \\ (x', y') = (x + \text{grid}, y - \text{grid}) \\ (x', y') = (x - \text{grid}, y + \text{grid}) \\ (x', y') = (x - \text{grid}, y - \text{grid}) \end{cases} \quad (8)$$

其中  $(x, y)$  表示AMR的当前状态,  $(x', y')$  表示AMR的下一个状态,  $\text{grid}$  表示一个单位网格的宽度。值得强调的是, AMR在网格环境中执行的每个动作只能将其移动到邻近的状态。




图 8. 目标区域图。

3) *Design of Reward Functions*: 在MDP框架中, 奖励函数用于评估代理 (AMR) 动作 $a$ 的价值。在之前的大多数研究中, 当接近目标区域时, AMR会获得正奖励, 当碰撞障碍物时, AMR会获得负奖励。然而, 其他状态的奖励值设置为零, 这导致了强化学习算法奖励稀疏的问题。因此, 我们引入了复合奖励函数 $R_t$ , 使智能体在算法训练过程中收到的奖励随着状态转换而变化。复合奖励函数可以表示为

$$R_t = r_{\tau 1} + r_{\tau 2} + r_{\tau 3} + r_{\tau 4} \quad (9)$$

其中 $r_{\tau 1}$ 是目标奖励函数,  $r_{\tau 2}$ 是距离奖励函数,  $r_{\tau 3}$ 是边界奖励函数,  $r_{\tau 4}$ 是障碍物奖励函数。

详细描述中,  $r_{\tau 1}$ 通常设置为正值, 用于激励AMR逼近TP, 计算公式为

$$r_{\tau 1} = \lambda_1 \left( TD \leq \frac{\sqrt{2}}{2} \text{grid} \right) \quad (10)$$

其中 $\lambda_1$ 表示正奖励值, 当AMR到达目标区域时可以获得。为了提高MDP模型训练效率, 当AMR到达TP周围的黄色区域时, 可以认为任务完成, 如图8所示。

距离奖励函数 $r_{\tau 2}$ 以欧几里德距离作为启发函数项[41], 可以减少DDQN算法在环境搜索过程中的盲目性, 提高规划效率。公式由下式给出

$$r_{\tau 2} = \lambda_2 \left( \sqrt{(x_k - x_{\text{target}})^2 + (y_k - y_{\text{target}})^2} \right) \quad (11)$$

其中 $\lambda_2$ 是一个负常数, 用于控制距离奖励函数的大小,  $(x_k, y_k)$ 表示AMR在时间 $k$ 的状态,  $(x_{\text{target}}, y_{\text{target}})$ 表示目标状态。这意味着如果AMR距离目标区域越近, 它将获得较小的负奖励值。因此,  $r_{\tau 2}$ 可以促进AMR快速到达目标区域。




图9.最小安全距离示意图。

边界奖励函数  $r_{\tau 3}$  可以将 AMR 运动限制在环境边界内，由下式给出

$$r_{\tau 3} = \begin{cases} \lambda_3, & (x > \max(x) \text{ or } x < \min(x) \\ & y > \max(y) \text{ or } y < \min(y)) \\ 0, & \text{otherwise.} \end{cases} \quad (12)$$

(12)中,  $\lambda_3$ 表示负常数值,  $\max(x)$ 和 $\min(x)$ 是环境的最大和最小水平坐标,  $\max(y)$ 和 $\min(y)$ 是环境的最大和最小垂直坐标。

由于AMR本体的宽度不可忽略, 障碍物奖励函数 $r_{\tau 4}$ 可以有效避免AMR在实际运动过程中与障碍物边缘发生碰撞的风险。  $r_{\tau 4}$  表示为

$$r_{\tau 4} = \begin{cases} \lambda_4, & OD < R_s \\ 0, & OD \geq R_s \end{cases} \quad (13)$$

其中 $\lambda_4$ 代表负值, 设置AMR与障碍物之间的最小安全距离OD为 $R_s$ , 以半径为 $R_s$ 的圆形区域作为最小安全区域, 具体如图9所示。当AMR与障碍物之间的距离小于 $R_s$  ( $R_s < 0.6$  m)时,  $r_{\tau 4}$ 给予AMR负奖励值 $\lambda_4$ ; 当障碍物出现在AMR ( $R_s \geq 0.6$  m)的最小安全区域之外时, 不存在碰撞风险, 奖励函数 $r_{\tau 4}$ 的值为0。

### B. Algorithms Proposed Path-Planning Algorithm of AMR

1) *Deep Neural Network*: 如图10所示, DDQN算法架构采用DNN来逼近状态-动作值函数[42]。此外, 当前网络和目标网络都采用相同的DNN结构。DNN 架构由1个输入层、3个隐藏层和1个输出层组成, 网络参数以监督方式学习。神经网络的输入数据由两部分组成: 1) 传感器扫描的环境信息和2) AMR的位置特征信息。这些数据通过全连接层进行处理, 并将计算结果传输到输出层。输出层提供  $Q$  值




图 10. 当前网络和目标网络的神经网络结构。

对应输出动作集合, 最终输出最大 $Q$ 值对应的动作。在该网络架构中, 整流线性单元 (ReLU) 被用作输入层和每个隐藏层的激活函数。

ReLU 函数可以表示为

$$h(\xi) = \begin{cases} \xi, & \xi > 0 \\ 0, & \xi \leq 0. \end{cases} \quad (14)$$

为了使DNN保持更好的学习效率, 在训练过程开始时将学习率设置为0.0025。然后, 利用自适应矩估计 (Adam) 算法来优化学习率, 可以实现学习率的自适应更新[43]。同时, Adam 结合了动量项来改进神经网络的随机梯度下降。随后结合防止梯度爆炸的方法对当前网络进行优化, 提高了DDQN算法的预测能力。

2) *Adaptive Action Selection Policy*: 探索和利用之间的平衡是强化学习算法面临的挑战。Agent (AMR) 需要充分利用学到的经验, 不断探索环境, 以获得更有效的长期行动策略。在先前的研究中, 解决这种困境的常见方法是利用固定的 $\epsilon$ -贪婪策略[44], AMR选择与其经验中的最大动作价值函数相对应的动作, 或者以一定的概率随机选择一个动作。然而, 过度依赖历史经验可能会导致AMR陷入局部最优, 从而无法获得全局最优解。相反, 过度探索可能会降低 AMR 的训练效率。

为了在探索和利用之间进行权衡, 本文提出了一种基于概率的非线性自适应  $\epsilon$ -贪婪动作选择策略, 其中概率  $\epsilon$  随着训练集的变化进行自适应调整。该策略可以引导 AMR 在训练的早期阶段广泛探索环境, 然后获取足够数量的训练样本。在训练后期, DDQN算法充分利用最优策略来加速收敛

**Algorithm 1** Adaptive  $\varepsilon$ -Greedy Policy

---

```

1: Generate a random probability value  $p, p \in (0, 1)$ 
2: If  $p < \varepsilon_k$  then
3:  $a = \text{random action}$ 
4: Else if  $p \geq \varepsilon_k$ 
5:  $a = \arg\max_a Q(s, a)$ 
6: End

```

---

算法。自适应动作选择策略可以表示为

$$\varepsilon_k = \varepsilon_f + \frac{\varepsilon_i - \varepsilon_f}{1 + e^{\frac{k}{\varepsilon_d}}} \quad (15)$$

其中 $\varepsilon_k$ 表示第 $k$ 集贪婪因子,  $\varepsilon_i$ 表示初始贪婪因子,  $\varepsilon_f$ 表示最终贪婪因子,  $\varepsilon_d$ 表示 $\varepsilon$ 贪婪因子的衰减率。第 $k$ 集的自适应 $\varepsilon$ 贪婪策略的伪代码在算法1中给出。

3) *Path Smoothing*: DDQN算法的输出动作是离散的, 而AMR在实际场景中的转向操作是连续的。为了更好地使规划路径更符合AMR的实际要求, 需要使用贝塞尔曲线来平滑规划路径, 因为它具有编程难度低、计算成本低、轨迹连续性强等优点[45], [46]。因此, DDQN算法框架中引入贝塞尔曲线来实现端到端的平滑路径规划。从一阶到三阶贝塞尔曲线的计算表达式为

$$p_i^k = \begin{cases} p_i^0, & i = 0, 1, 2, \dots, n-k \\ (1-t)p_i^{k-1} + tp_{i+1}^{k-1}, & i = 0, 1, 2, \dots, n-k \end{cases} \quad (16)$$

其中,  $p_i^0$ 表示第 $i$ 个初始控制点,  $p_i^k$ 表示第 $i$ 个 $K$ 阶控制点 ( $k=1,2,\dots,n$ ),  $t$ 表示比例系数。

根据(16)式,  $n$ 阶控制点的计算公式总是包含两个 $n-1$ 阶控制点, 因此最终可以根据初始控制点计算出 $n$ 阶控制点的计算公式。二阶贝塞尔曲线可以保证路径的平滑性, 并且比高阶贝塞尔曲线具有更快的计算速度。因此, 串联多条二阶贝塞尔曲线来平滑路径的转折点, 计算表达式为

$$B(t) = (1-t^2)p_i^0 + 2(1-t)p_{i+1}^0 + t^2p_{i+2}^0, t \in [0, 1] \quad (17)$$

其中 $p_i^0$ 、 $p_{i+1}^0$ 和 $p_{i+2}^0$ 表示三个连续的初始化控制点。

4) *AMR Path-Planning Algorithm Process*: 综上所述, 1 DDQN算法应用于AMR路径规划的流程图如图10所示。该算法的伪代码如算法2所示, 图11中连接线上的数字对应于算法2的流程。算法2的流程大致如下所示。

*Step 1*: 首先设置训练参数, 主要包括状态空间、动作集、初始学习率等;

算法2 基于IDDQN的AMR路径规划算法1: 输入: 交互次数 $N$ ; 动作集 $A$ ; 学习率 $\alpha$ ; 折扣系数 $\gamma$ ; 体验重播池最大大小 $D$ ; 小批量 $M$ ; 当前神经网络值 $Q$ ; 目标神经网络值 $Q'$ 。2: 初始化网络参数 $\theta$ 和 $\theta'$ , 令 $\theta' = \theta$ , 并初始化重放池 $R$ 。3: 设置最大步数 $n_{max}$ 。4: 对于第1集, 执行

5: 初始化环境空间并获取起始状态 $s = (x_0, y_0)$ 。

6: 对于步骤=1, 执行7:  $S$ 为当前状态的输入, 获取当前状态对应的所有 $Q$ 值输出, 并使用自适应 $\varepsilon$ 贪婪策略来选择 $Q$ 值对应的动作。设置 $a_t =$

$$\begin{cases} \arg \max_{a'} Q(s, a; \theta) \text{ with probability } 1 - \varepsilon \\ \text{random action} & \text{otherwise} \end{cases}$$

8: 动作 $a$ 由AMR执行, AMR与外部环境交互接收奖励 $r$ 和下一个状态 $s'$ 。9: 将 $(s, a, r, s')$ 存储到经验回放池中。

10: Let  $s = s'$ .

11: 从 $D$ 开始的 $R$ 过渡 $(s_i, a_i, r_i, s'_i)$ 的随机样本小批量, 并计算目标 $Q$ 值的 $y_{i0}$

$$12: \text{Set } y_i = \begin{cases} r_i & \text{if episode terminates at step } i \\ r_i + \gamma Q'(s', \arg \max_{a'} Q(s', a'; \theta); \theta^-) & \text{otherwise} \end{cases}$$

13: 计算损失函数 $L(\theta) = E[(y_i - Q(s, a; \theta))^2]$ , 通过神经网络的梯度方向反向传播来更新参数 $\theta$ 。14: 替换目标参数:  $\theta^- = \tau\theta + (1-\tau)\theta^-$ 。15: 如果 $s'$ 为目标状态, 则当前交互结束, 然后使用Bezier曲线平滑路径。否则进入第7步。

16: 输出: 最优路径向量集。17: 结束

18: 结束

其次, 建立当前神经网络和目标神经网络; 第三, 随机初始化参数 $\theta$ 和 $\theta^-$ , 以及 $\theta = \theta^-$  (第2行)。

*Step 2*: AMR探索环境的过程 (第5-8行)。在每个episode开始时, 都会初始化环境信息, 并且在探索过程中, 将当前状态输入到当前网络, 并输出相关动作的 $Q$ 值 (第5行和第6行)。使用改进的自适应 $\varepsilon$ 贪婪策略获取并执行操作 $a$  (第7行)。AMR与环境交互以接收奖励 $r$ 和接下来的状态 $s$  (第8行)。

*Step 3*: 当前和目标神经网络的更新过程 (第9-14行)。首先, 将发现过程中获得的多样化样本数据保存在经验回放数据池中, 然后从经验池中随机采样小批量的经验数据来更新当前网络 (第9-11行)。目标 $Q$ 值在 (第12行) 中更新。其次, 基于神经网络梯度的反向传播, 计算损失函数, 并






图 12. 不同路径规划方法的仿真结果。

A\*算法可以表示为 $O(N_1 \log N_1)$ , 其中 $N_1$ 表示节点数量。APF算法的时间复杂度表达式为 $O(N_2 * M)$ , 其中 $N_2$ 表示迭代次数,  $M$ 表示障碍物数量。此外, RRT算法的时间复杂度为 $O(N_3^2)$ , 其中 $N_3$ 表示树的顶点数。

### B. Simulations Under Unknown Environment Without Disturbance

这里, 设计了四种具有不同地形特征和障碍物密度的未知环境来评估所提出的 IDQN 算法的性能。首先, 建立五个关键绩效指标 (KPI) 来评估各种路径规划算法的性能。KPI 包括路径拐角数 (PC)、最大路径转向角度 (MPTA)、最小碰撞距离 (MDTC)、平均路径长度 (APL) 以及算法 IT。这五种算法在四种不同仿真环境下的规划路径如图 12 所示, KPI 值如表 2 所示。

如图 12 所示, 所有五种路径规划算法都可以在四种不同的未知环境中成功生成无碰撞路径。一方面, 基于三种常用传统的轨迹规划

通过与 APF、RRT、A\* 等路径规划方法的比较, 以及表 2 中 KPI 的对比分析, 可以看出 APF 算法可以在保证运动安全的前提下实时计算 AMR 运动轨迹。然而, APF 算法容易陷入局部最小值, 这可能导致生成的路径中存在局部振荡和较长的路径长度。RRT 算法在路径规划中表现出较高的搜索效率。然而, RRT 算法生成的路径路径长度较长、路径转折点较多、路径轨迹距离障碍物较近, 无法保证 AMR 路径规划的安全性。另外, 虽然 A\* 算法规划的路径相对较短、转弯点较少, 但 A\* 算法生成的轨迹存在与障碍物边缘发生碰撞的风险。而且, 随着环境复杂度的增加, A\* 算法的 IT 也会显着增加。另一方面, 通过比较 DQN 和 IDQN 算法在四种未知复杂环境下路径规划的性能结果, 可以得出结论, DQN 和 IDQN 算法生成的轨迹可以保持与障碍物的距离至少 0.5 m, 并且总体上优于三种传统路径规划算法。更重要的是, 与 DQN 算法相比, IDQN 算法的 APL 是,

表2 不同路径规划算法的KPI比较

| Environment No. | Algorithm name | KPIs                    |                        |                                |                    |                       |
|-----------------|----------------|-------------------------|------------------------|--------------------------------|--------------------|-----------------------|
|                 |                | Average path length (m) | Number of path corners | Mini collision to obstacle (m) | Inference time (s) | Max corner degree (°) |
| Env. (a)        | IDDQN          | 21.428                  | 4                      | 0.749                          | 0.00094            | 15                    |
|                 | DQN            | 24.264                  | 3                      | 0.5                            | 0.00104            | 45                    |
|                 | APF            | 23.406                  | 6                      | 1.1486                         | 0.0582             | 83                    |
|                 | RRT            | 31.426                  | 13                     | 0.2434                         | 0.0491             | 120                   |
|                 | A*             | 22.484                  | 2                      | 0                              | 0.1305             | 45                    |
| Env. (b)        | IDDQN          | 35.842                  | 6                      | 0.7494                         | 0.00117            | 41                    |
|                 | DQN            | 39.799                  | 14                     | 0.7071                         | 0.00121            | 45                    |
|                 | APF            | 66.369                  | 9                      | 1.4296                         | 0.0630             | 62                    |
|                 | RRT            | 50.988                  | 23                     | 0.9096                         | 0.0512             | 117                   |
|                 | A*             | 36.704                  | 4                      | 0                              | 0.3725             | 45                    |
| Env. (c)        | IDDQN          | 39.229                  | 3                      | 0.7071                         | 0.00110            | 41                    |
|                 | DQN            | 42.300                  | 9                      | 0.5                            | 0.00132            | 45                    |
|                 | APF            | 43.408                  | 12                     | 1.4467                         | 0.0716             | 84                    |
|                 | RRT            | 48.678                  | 24                     | 0.0386                         | 0.0622             | 139                   |
|                 | A*             | 39.742                  | 5                      | 0                              | 0.6673             | 45                    |
| Env. (d)        | IDDQN          | 28.248                  | 5                      | 0.7071                         | 0.00147            | 21                    |
|                 | DQN            | 31.324                  | 10                     | 0.5                            | 0.00151            | 45                    |
|                 | APF            | 31.559                  | 11                     | 1.4619                         | 0.0733             | 60                    |
|                 | RRT            | 39.781                  | 16                     | 0.3742                         | 0.0617             | 103                   |
|                 | A*             | 30.612                  | 5                      | 1.4142                         | 0.6304             | 45                    |

在四种复杂环境下分别降低了11.69%、8.49%、7.26%和9.82%，IDDQN算法生成的规划路径具有更好的平滑性和更少的路径拐点。

图13揭示了DQN和IDDQN算法在四种不同环境下训练过程中奖励值的变化。由于在我们提出的IDDQN算法的早期训练阶段，代理（AMR）对环境进行了广泛的探索，IDDQN算法的奖励函数曲线出现了明显的振荡。随后，AMR 通过利用从探索中获得的经验知识来加速学习过程，最终实现学习奖励的稳定。随着障碍物环境复杂性的增加，IDDQN和DQN都需要更多的探索步骤才能使奖励值变得稳定。尽管DQN算法经过一段时间的不断学习和试错后可以实现奖励曲线的稳定性，但由于对Q值的高估以及存在过多无效的动作选择策略，其收敛速度较慢。此外，奖励曲线在训练过程的后期表现出显著的波动。通过比较所提出的IDDQN和DQN的奖励值变化趋势，可以看出，在四种不同环境下，IDDQN算法获得稳定奖励值所需的迭代步数比DQN算法减少了约27.31%、32.17%、52.91%和26.40%。比较结果表明IDDQN具有更高的学习效率、全局搜索能力和良好的收敛性。

图14所示的雷达图是根据表II记录的数据生成的，有助于分析IDDQN算法与其他四种算法之间路径规划性能的差异。从图14可以看出，IDDQN算法模型的推理速度远优于APF、RRT、A\*算法




图13.训练过程中IDDQN和DQN奖励值的变化。

四种实验环境下。IDDQN算法生成的路径的路径长度、转弯点数、最大转弯角度均小于DQN算法等传统方法。因此，IDDQN算法采用端到端的训练模式，具有更好的综合路径规划能力。

### C. Simulations Under Unknown Environment With Disturbance

AMR在运动过程中可能会受到外界环境因素的变化，如路面摩擦力不足、地面条件不均匀等，从而导致AMR稳定性差，出现定向滑移。因此，




图14.四种环境下不同路径规划算法的KPI比较结果。

AMR的动议将由行动选择政策和外部环境信息决定。具体来说，位移扰动对AMR路径规划的影响可以描述为：AMR经过随机扰动 $(x, y)_{\text{current}}$ 的位置，到达下一个状态 $(x, y)_{\text{next}}$ 后，会在 $x$ 轴或 $y$ 轴方向产生随机偏移 $(a, b)$ ，其中 $(x, y)_{\text{next}}$ 可以描述为 $(x, y)_{\text{next}} = (x, y)_{\text{current}} + (a, b)$ 。

为了评估所提出的IDDQN算法在具有随机扰动的未知环境中的适应性和鲁棒性，在两个尺寸为 $20 \times 20$ 的单目标复杂障碍物环境和两个尺寸为 $30 \times 30$ 的多目标复杂障碍物环境中随机设置多种类型的扰动。单目标环境中随机扰动的位置和大小记录在表III中。在多目标环境中，AMR的路径规划过程按每个目标区域分为不同的阶段，AMR每个运行阶段的随机扰动的位置和大小记录在表IV中。IDDQN算法在有干扰和无干扰的训练环境下的路径规划结果如图15所示。

同时，图16提出了五个KPI来评估环境干扰对路径规划结果的影响。这些KPI包括APL、达到稳定奖励值(TS)所需的总探索步骤、最小碰撞距离(MDTC)、PC数量和MPTA。

从图15可以看出，IDDQN算法使得AMR能够避开障碍物并到达每个目标区域，无论单目标环境或多目标环境中是否存在干扰。

表 III 单目标障碍物环境中的随机扰动

分布和大小

| Environments      | Disturbances | $(a, b)$ |
|-------------------|--------------|----------|
| Single target (a) | $x=5.5$      | $(0, 1)$ |
|                   | $y=12.5$     | $(0, 1)$ |
| Single target (b) | $x=5.5$      | $(0, 1)$ |
|                   | $y=9.5$      | $(1, 0)$ |

表 IV 多目标障碍物环境中的随机扰动分

布和大小

| Environments                    | Phases  | Disturbances | $(a, b)$  |
|---------------------------------|---------|--------------|-----------|
| Multiple continuous targets (b) | Phase 1 | $x=8.5$      | $(0, 1)$  |
|                                 | Phase 2 | $y=14.5$     | $(1, 0)$  |
|                                 | Phase 3 | $x=18.5$     | $(0, 1)$  |
| Multiple continuous targets (c) | Phase 1 | $x=9.5$      | $(0, 1)$  |
|                                 | Phase 2 | $x=12.5$     | $(-1, 0)$ |
|                                 | Phase 3 | $y=23.5$     | $(-1, 0)$ |
|                                 | Phase 4 | $x=18.5$     | $(0, 1)$  |

然而，环境干扰的存在导致IDDON算法规划的路径与未干扰环境中规划的路径存在偏差。此外，环境中的干扰信息和连续TP越多，路径偏差就越显着。在环境干扰下，与无干扰的路径规划相比，IDDON生成的最终路径更长并且包含更多的路径转折点。

通过比较图15中的KPI数据，可以发现IDDQN算法的路径长度和总探索步数受环境影响显着。




图1 5. (a)和(b)单目标未知扰动环境下AMR的轨迹。(c)和(d) AMR 在多目标未知中的轨迹  
干扰 平衡环境。

两个不同环境中的干扰。特别是，根据图15 (d)，在未知干扰环境下获得的路径长度比原始路径增加了10.12%，IDDQN算法达到稳定奖励值所需的探索步骤数增加了66.06%。另外，IDDQN算法需要在避开障碍物的同时减轻环境中随机扰动的影响，导致生成的路径具有更大的转弯角度和更多的路径转折点。仿真实验表明，环境中的随机扰动并不妨碍IDDQN算法规划AMR到达所有目标区域的最佳路径，同时保证路径轨迹与不同障碍物保持最小安全距离。然而，环境中存在的干扰会增加IDDQN算法的计算需求。综上所述，IDDQN算法会在未知环境中从头开始不断学习扰动信息，能够表现出一定程度的适应性和鲁棒性。所提出的IDDQN算法模型可以扩展以适用于更多环境，为AMR路径规划提供了新的解决方案。

## 五、结论

本文提出一种改进的DDQN算法来处理综合未知环境下的AMR路径规划问题。最初，在建立AMR路径规划MDP模型后，设计了综合奖励函数，以将AMR快速导航到目标区域，同时确保AMR与障碍物保持安全距离。然后，在DDQN算法框架中，融合了自适应 $\epsilon$ -贪婪策略和优化的DNN，提高了DDQN算法的全局搜索能力和收敛速度。此外，还引入了贝塞尔曲线算法来平滑DDQN输出的离散动作。最后，在各种综合未知环境下对IDDQN算法进行了验证。在四组未知环境中，与DQN、A\*、RRT和APF算法相比，所提出的IDDQN算法规划的路径不仅对于AMR来说更安全、更短，而且其推理速度也远优于传统方法。同时，通过评估IDDQN算法在随机干扰的未知环境下，无论是单目标还是多目标场景，进一步证明IDDQN算法表现出更好的适应性和鲁棒性。




图 16. 不同环境下干扰对 AMR 路径规划的影响。

在未来的工作中, 我们将重点研究基于传感器的动态路径规划, 并在硬件在环实验中进行实际算法验证。

#### 参考

- [1] A. Loganathan and N. S. Ahmad, “自主移动机器人导航最新进展的系统回顾”, *Eng. Sci. Techno., Int. J.*, 卷。2023 年 4 月 40 日, 艺术。不。[2] F. H. Ajeil, I. K. Ibraheem, M. A. Sahib and A. J. Humaidi, “使用混合 PSO-MFB 优化算法的自主移动机器人的多目标路径规划”, *Appl. Soft Comput.*, 卷。89, 2020 年 4 月, 艺术。不。106076. [3] 李建, 赵斌, 徐锋, “电力设备检修环境下智能机器人动态路径规划”, *Energy Rep.*, 第 106076 期。9, 第 784-791 页, 2023 年 9 月。[4] X. S. un, S. Deng, B. Tong, S. Wang, C. Zhang 和 Y. Jiang, “移动机器人有效自主探索未知环境的分层框架”, *ISA Trans.*, 卷。134, 第 1-15 页, 2023 年 3 月。[5] Y. Ma, Y. Zhu, Z. Li, X. Yan, H. Bi 和 G. Król czyk, “一种基于 A 星搜索的无人地面测绘车辆新覆盖路径规划算法”, *Appl. Ocean Res.*, 卷。123, 2022 年 6 月, 艺术。不。103163. [6] Y. Liu, P. Huang, F. Zhu, and Y. Zhu, “约束多智能体系统中使用人工势和神经网络的分布式编队控制”, *IEEE Trans. Control Syst. Technol.*, 第 103163 卷。28, 没有。[7] G. Ma, Y. Duan, M. Li, Z. Xie, and J. Zhu, “室内机器人概率平滑 Bi-RRT 路径规划算法”, *Future Gener. Comput. Syst.*, 第 2 期, 第 697-704 页, 2020 年 3 月。143, 第 349-360 页, 2023 年 6 月。[8] X. Yu, W.-N. Chen, T. Gu, H. Yuan, H. Zhang and J. Zhang, “ACO-A\*: 蚁群优化加 A\*, 用于在障碍物密集的环境中进行 3D 旅行”, *IEEE Trans. Evol. Comput.*, 第 1 卷。23, 没有。4, 第 617-631 页, 2019 年 8 月。[9] L. Li, D. Wu, Y. Huang and Z. M. Yuan, “基于深度强化学习和人工势场的与 COLREGS 碰撞避免功能相结合的路径规划策略”, *Appl. Ocean Res.*, 卷。113, 2021 年 8 月, 艺术。不。102759。

- [10] Z. Lin, M. Yue, G. Chen, J. Sun, “移动障碍物下基于 PSO 的 APF 和基于模糊的 DWA 的移动机器人路径规划”, 第 13 卷。44, 没有。1, 第 121-132 页, 2022 年。[11] J. Ding, Y. Zhou, X. Huang, K. Song, S. Lu, and L. Wang, “一种基于路径扩展启发式采样的机器人路径规划改进 RRT 算法”, *J. Comput. Sci.*, 卷。67, 2023 年 3 月, 艺术。不。101937. [12] Z. Yu, Z. Si, X. Li, D. Wang, and H. Song, “一种用于无人机路径规划的新型混合粒子群优化算法”, *IEEE Internet Things J.*, vol. 10 1937. 9, 不。22, 第 22547-22558 页, 2022 年 11 月。[13] C.-C. 蔡, H.-C. 黄, 和 C.-K. Chan, “并行精英遗传算法及其在自主机器人导航全局路径规划中的应用”, *IEEE Trans. Ind. Electron.*, 卷。58, 没有。10, 第 4813-4821 页, 2011 年 10 月。[14] H. Yang, J. Qi, Y. Miao, H. Sun, J. Li, “一种基于双层蚂蚁算法和轨迹优化的新型机器人导航算法”, *IEEE Trans. Ind. Electron.*, vol. 10, 第 4813-4821 页, 2011 年 10 月。6, 没有。11, 第 8557-8566 页, 2019 年 11 月。[15] M. L. Littman, “强化学习通过评估反馈改善行为”, *Nature*, 卷。521, 没有。7553, 第 445-451 页, 2015 年。[16] R. Liu, M. Xie, A. Liu 和 H. Song, “采用微型 ML 无人机互联网的物联网网络中的联合优化风险因素和能耗”, *IEEE Internet Things J.*, 早期访问, 2024 年 1 月 1 日, doi: 10.1109/IOT.2023.3348837. [17] M. Pflueger, A. Agha 和 G. S. Sukhatme, “Rover-IRL: 用于行星漫游器路径规划的软值迭代网络的逆强化学习”, *IEEE Robot. Autom. Lett.*, 卷。4, 没有。2, 第 1387-1394 页, 2019 年 4 月。[18] B. Wang, Z. Liu, Q. Li 和 A. Prorok, “通过全局引导强化学习在动态环境中进行移动机器人路径规划”, *IEEE Robot. Autom. Lett.*, 卷。5, 没有。4, 第 6932-6939 页, 2020 年 10 月。[19] Q. Zhou, Y. Lian, J. Wu, M. Zhu, H. Wang, and J. Cao, “一种用于移动机器人本地路径规划的优化 Q-Learning 算法”, *Knowl. Based Syst.*, 卷。286, 2024 年 2 月, 艺术。不。111400. [20] E. S. Low, P. Ong 和 K. C. Cheah, “使用改进的 Q 学习解决移动机器人的最优路径规划”, *Robot. Auton. Syst.*, 卷。115, 第 143-161 页, 2019 年 5 月。[21] M. Pei, H. An, B. Liu, and C. Wang, “未知动态环境下移动机器人路径规划的改进 Dyna-Q 算法”, *IEEE Trans. Syst., Man, Cybern., Syst.*, 卷。52, 没有。7, 第 4415-4425 页, 2022 年 7 月。

[22] C. S. Tan, R. Mohd-Mokhtar and M. R. Arshad, “用于机器人路径规划的预期平均伽玛增量强化学习算法”, *Expert Syst. Appl.*, 卷. 249, 2024 年 9 月, 艺术. 不. 123539. [23] 杨建, 倪建, 奚明, 文建, 李勇, “基于强化学习的水下机器人智能路径规划”, *IEEE Trans. Autom. Sci. Eng.*, 第 123539 期. 20, 没有. 3, 1983-1996 页, 2023 年 7 月. [24] Z. Chu, F. Wang, T. Lei, C. Luo, “洋流扰动下基于深度强化学习的自主水下航行器路径规划”, *IEEE Trans. Intell. Veh.*, 卷. 8, 不. [25] Y. 晓飞, S. 一伦, L. Wei, Y. Hui, Z. Weibo, X. Zhengrong, “基于双 DQN 的多任务两栖无人水面艇全局路径规划算法”, *Ocean Eng.*, 第 1 期, 第 108-120 页, 2023 年 1 月. 266, 2022 年 12 月, 艺术. 不. 11280 9. [26] 于丽, 吴凤, 徐子, 谢子, 杨东, “基于深度强化学习的连通性约束无人机路径设计”, *Phys. Commun.*, 第 112809 期. 2022 年 6 月 52 日, 艺术. 不. 101582. [27] 郑坤, 杨红, 刘世, 张坤, 雷丽, “一种基于强化学习的自动驾驶行为决策方法”, *IEEE Internet Things J.*, 第 1 01582 期. 9, 不. 24, 第 25386-25394 页, 2022 年 12 月. [28] S. Wen, Y. Zhao, X. Yuan, Z. Wang, D. Zhang, L. Manfredi, “未知环境下基于深度强化学习的主动 SLAM 路径规划”, *Intell. Service Robot.*, 卷. 13, 第 263-272 页, 2022 年. [29] K. Wu, H. Wang, M. A. Esfahani and S. Yuan, “BND\*-DDQN: 通过深度强化学习学习自动驾驶”, *IEEE Trans. Cogn. Develop. Syst.*, 卷. 13, 没有. 2, 第 249-261 页, 2 021 年 6 月. [30] X. Wang, H. Fu, G. Deng, C. Liu, K. Tang and C. Chen, “使用深度强化学习的六足机器人的分层自由步态运动规划”, *IEEE Trans. Ind. Informat.*, 卷. 19, 没有. 11, 第 10901-10912 页, 20 23 年 11 月. [31] X. Tao 和 A. S. Hafid, “DeepSensing: 一种具有双深度 q 网络和优先体验重播的新型移动群智感知框架”, *IEEE Internet Things J.*, 卷. 7, 没有. 12, 第 11547-11558 页, 20 20 年 12 月. [32] J. Jiang, X. Zeng, D. Guzzetti and Y. You, “采用预训练深度强化学习架构的小行星跳跃漫游器的路径规划”, *Acta Astronautica*, 卷. 171, 第 265-279 页, 2020 年 6 月. [33] W. Lan 等人, “使用深度强化学习在时变洋流中进行水下滑翔机的路径规划”, *Ocean Eng.*, 卷. 262, 2022 年 10 月, 艺术. 不. [34] M. Xi, J. Yang, J. Wen, H. Liu, Y. Li, and H. H. Song, “基于强化学习的综合海洋信息支持的 AUV 路径规划”, *IEEE Internet Things J.*, vol. 112226. 9, 不. 1 8, 第 17440-17451 页, 2022 年 9 月. [35] W. Zhang, J. Gai, Z. Zhang, L. Tang, Q. Liao 和 Y. Ding, “基于双 DQN 的机器人车辆导航路径平滑和跟踪控制方法”, *Comput. Electron. Agric.*, 卷. 166, 2019 年 11 月, 艺术. 不. 104985. [36] V. Mnih 等人, “通过深度强化学习实现人类水平的控制”, *Nature*, 卷. 518, 没有. 7540, 第 529-533 页, 2015. [37] S. Wen, Z. Wen, D. Zhang, H. Zhang 和 T. Wang, “基于迁移学习的使用元强化学习的自主导航多机器人路径规划算法”, *Appl. Soft Comput.*, 卷. 110, 2021 年 10 月, 艺术. 不. 107605. [38] H. Van Hasselt, A. Guez 和 D. Silver, “采用双 q 学习的深度强化学习”, *Proc. AAAI Conf. Artif. Intell.*, 2016 年, 第 2094-2100 页. [39] A. Kovalev, S. Karlsson 和 G. Nikolakopoulos, “受限环境中基于自主地图的点导航的实验评估”, *Biomim. Intell. Robot.*, 卷. 2, 没有. 2022 年 1 月 1 日, 艺术. 不. [40] Y. Wu, F. Xie, L. Huang, R. Sun, J. Yang, and Q. Yu, “无先验全局地图的卷积评估梯度优先搜索路径规划算法”, *Robot. Auton. Syst.*, vol. 100035. 150, 2022 年 4 月, 艺术. 不. 103985. [41] J. Wen, J. Yang 和 T. Wang, “基于融合启发式算法的洋流影响下的自主水下航行器路径规划”, *IEEE Trans. Veh. Technol.*, 卷. 70, 没有. 9, 第 8529-8544 页, 2021 年 9 月. [42] B. Hadi, A. Khosravi 和 P. S. Arhadi, “用于自主水下航行器自适应路径规划和控制的深度强化学习”, *Appl. Ocean Res.*, 卷. 129, 2022 年 12 月, 艺术. 不. 103326. [43] G. Chen, Z. Gau, M. Hua, B. Shuai, and Z. Gau, “考虑自动驾驶汽车驾驶风格不确定性的车道变换轨迹预测”, *Mech. Syst. Signal Process.*, 卷. 206, 2024 年 1 月, 艺术. 不. 110854. [44] A. Bozanta 等人, “使用强化学习的食品配送服务的快递路线和分配”, *Comput. Ind. Eng.*, 卷. 164, 2022 年 2 月, 艺术. 不. 107871.

[45] B. Song, Z. Wang, L. Zou, “一种改进的 PSO 算法, 用于使用连续高阶贝塞尔曲线的移动机器人平滑路径规划”, *Appl. Soft Comput.*, 卷. 100, 2021 年 3 月, 艺术. 不. 106960. [46] G. Klancar 和 S. Blazic, “最佳恒定加速度运动基元”, *IEEE Trans. Veh. Technol.*, 卷. 68, 没有. 9, 第 8502-8511 页, 2019 年 9 月. [47] C.-b. Moon 和 W. Chung, “使用快速探索随机树的两轮移动机器人的运动动力学规划器双树 RRT (DT-RRT)”, *IEEE Trans. Ind. Electron.*, 卷. 62, 没有. 2, 第 1080-1090 页, 2015 年 2 月. [48] B. Fu 等人, “一种成功率高、长度短的工业机器人路径规划的改进 A\* 算法”, *Robot. Auton. Syst.*, 第 106 卷, 第 26-37 页, 2018 年 8 月.



白泽坤获得理学学士学位他于 2021 年在中国汉中的陕西理工大学获得车辆工程学士学位。他目前正在攻读硕士学位。西安理工大学机械与精密仪器工程学院机械工程专业, 获工学博士学位。

主要研究兴趣包括强化学习、路径规划和车辆智能控制。



庞辉 (IEEE 会员) 获得理学学士学位 2002 年毕业于郑州航空工业管理学院机械制造及其自动化专业, 获工学学士学位; 和博士学位。分别于 2005 年和 2009 年获得西北工业大学机械工程学士学位。

现任西安理工大学机械与精密仪器工程学院教授。2016 年 11 月至 2017 年 11 月期间, 他担任

美国南卡罗来纳州格林维尔克莱姆森大学汽车工程系访问学者。他的研究兴趣包括非线性鲁棒控制和模糊滑模控制及其在车辆动力学控制中的应用。




何兆年获得学士学位他于 2022 年在中国聊城聊城大学获得机械工程博士学位。他目前正在攻读硕士学位。西安理工大学机械与精密仪器工程学院机械工程专业, 获工学博士学位。

主要研究方向为无人车路径规划与控制。



赵斌获得理学学士学位他于 2023 年在中国哈尔滨黑龙江工业学院获得车辆工程学士学位。他目前正在攻读硕士学位。西安理工大学机械与精密仪器工程学院机械工程专业, 获工学博士学位。

主要研究兴趣包括深度强化学习、路径规划和车辆智能控制。



王童获得理学学士学位他于 2023 年获得中国西安工业大学机械设计、制造及其自动化学士学位, 目前正在该校机械与精密仪器工程学院攻读机械工程硕士学位。

主要研究兴趣包括深度强化学习、智能车辆轨迹跟踪和路径规划。