

在传感器被拒绝的环境中 对深度强化学习进行 导航基准测试

Mariusz Wisniewski、Paraskevas Chatzithanos、郭伟思、Ant
onios Tsourdos

克兰菲尔德大学自主和网络物理系统中心，地址：College Road,
Cranfield, MK43 0AL, Bedfordshire, UK。

*通讯作者。电子邮件：m.wisniewski@cranfield.ac.uk；

Abstract

深度强化学习（DRL）用于在未知环境中实现自主导航。大多数研究都假设传感器数据是完美的，但现实世界的环境可能包含自然和人为的传感器噪声和否认。在这里，我们提出了导航任务中常用和新兴 DRL 算法的基准，具有可配置的传感器拒绝效果。特别是，我们有兴趣比较不同的 DRL 方法（例如无模型 PPO 与基于模型的 DreamerV3）如何受到传感器拒绝的影响。我们表明，DreamerV3 在具有动态目标的视觉端到端导航任务中优于其他方法 - 而其他方法无法学习这一点。此外，在没有传感器的环境中，DreamerV3 通常优于其他方法。为了提高鲁棒性，我们使用对抗性训练并在拒绝环境中展示了改进的性能，尽管这通常会在普通环境中带来性能成本。我们预计不同 DRL 方法的基准和对抗性训练的使用将成为开发更精细的导航策略的起点，这些策略能够处理不确定和否认的传感器读数。

Keywords: 自治;导航;传感器融合；深度强化学习；机器学习；复杂的环境；传感器故障；传感器故障；对抗性攻击；对抗训练；对抗性环境扰动

1 Introduction

自主导航是无人系统的基本挑战。传统的自主系统通常使用同步定位和建图（SLAM）以及卡尔曼滤波器，融合来自多个源的数据来绘制环境图、定位代理并生成到达目标的轨迹。近年来，深度强化学习（DRL）方法已被用来训练可以使用摄像头进行导航的端到端策略。这些改进得益于数字图像处理的进步，这主要归功于使用反向传播 [1-3] 训练的卷积神经网络，以及使用深度神经网络 [4] 的强化学习参数化。

虽然自主视觉导航可以在模拟环境中实现 [5]，但大多数研究都假设传感器读数完美。但是，在现实场景中，有关环境的信息可能是不确定的、不完整的，甚至是故意否认的。这会限制导航系统适应环境变化并做出最佳决策的能力。对于安全关键型操作（例如无人机或自动道路车辆），需要了解这些故障模式及其对系统的影响。对于众所周知难以解释的 DRL 代理来说，研究传感器伪影或故障如何影响训练和评估非常重要。

此外，实际系统通常使用一套传感器。虽然 DRL 的许多前沿工作都集中在端到端视觉导航上，但在实践中，了解模型如何通过从多个传感器获取数据来跨不同模式进行学习非常重要。在这项工作中，我们研究传感器故障如何影响使用相机或激光雷达作为观察空间的策略的训练和评估。

为了了解传感器噪声和故障的影响，我们比较了几种 DRL 架构：TD3、PPO、PPO-LSTM 和 DreamerV3。TD3 和 PPO 常用于评估具有连续动作空间的环境，PPO-LSTM 是 PPO 的循环版本（Mirowski 等人 [6] 证明循环模型优于非循环模型），而 DreamerV3 使用自动编码器创建环境的内部世界模型，并在某些环境中表现优于 PPO。

我们在“普通”环境中生成了它们的性能基线，传感器没有受到干扰（噪音或故障）。然后，我们逐步将随机区域添加到传感器受到干扰的环境中。然后对这些策略进行评估，以了解它们在不同程度的噪音下导航的成功程度。为了训练和评估这些方法，我们使用基于 ROS 的体育馆环境的修改版本来训练导航策略，*DRL-Robot-Navigation* [7]。它包含一个 3D 迷宫，其中机器人的任务是导航到目标。本出版物是 ICUAS 2024 上发表的自主导航会议论文的延伸[8]。

1.1 Review of DRL Applications to Navigation

一些研究已经在模拟环境中使用 DRL 并以摄像头作为唯一传感器实现了端到端导航 [9]。流行的环境包括 DeepMind Lab [10]、ViZDoom [11] 和 DRL-Robot-Navigation [7]。

米罗斯基等人。[6] 展示了 A3C [12] 算法在 Deepmind Lab 环境中的应用。他们使用相机作为唯一的传感器，其性能最佳的架构由图像编码器、2 个 LSTM 层、深度和循环预测组成。智能体因达到目标或子目标而获得水果形式的奖励。智能体不会因墙壁碰撞而受到惩罚，从而允许采取不需要记忆的“墙壁跟随”等策略。DRL 还可用于在静态环境中将图像传感器与 IMU（组合起来检测门并生成输入到 DRL 算法的 VI O 状态输入）相结合，让 FPV 无人机 (UAV) 与专业人类飞行员进行竞赛 [13]。波尔瓦拉等人。展示了如何使用 DQN 层次结构来实现无人机的自主着陆 [14]。他们的方法可以处理各种各样的模拟环境，并且在某些条件下优于人类飞行员。用于端到端自动驾驶的可解释的深度强化学习方法可以处理复杂的城市场景[15]。他们的方法优于许多基线，包括在有周围车辆的城市场景中的深度 Q 网络 (DQN)、深度确定性策略梯度 (DDPG)、双延迟 DDPG (TD3) 和 Soft Actor Critic (SAC)。Pasukonis 等人评估了 3D 迷宫中 FPV 智能体的记忆。[16]。他们发现，Dreamer 和 IMPALA 等模型可以在较小的迷宫 (9x9) 上与人类相匹配，但它们在较大的迷宫 (15x15) 上的表现会显著下降。Lample 和 Chaplot [17] 表明，DRL 可用于训练智能体玩第一人称射击游戏《DO OM》，其中智能体需要导航 3D 迷宫、收集物品并向敌人射击。他们发现，通过将 DQN 和 DQRN 与 LSTM 层结合使用，代理可以收敛，但需要添加预测游戏功能（使用单独的损失函数）才能可靠地射击敌人。近年来，人们提出了液体神经网络[18]来实现针对不断变化的环境的鲁棒导航[19]。在大多数情况下，虽然物理环境未知或随机，但论文并未考虑受损的传感器读数（考虑噪声和其他扰动的液体神经网络除外）。

1.2 Review of Sensor Fusion under Attacks

1.2.1 Trajectory Estimation Approaches

第一种方法处理间歇性攻击或拒绝，例如当 GNSS 覆盖范围丢失时，使用卡尔曼滤波器（或更先进的循环神经网络）来保持轨迹估计，直到覆盖范围恢复 [20, 21]。这对于短暂的中断很有用。同样的想法可以先发制人地发现其他V2V网络以改善本地化[22]。然而，如果环境需要持续的急剧机动以避免动态物体，则这种情况排除了轨迹估计方法。此外，如果攻击是连续的并削弱了保持精度，则这将是不合适的。

1.2.2 Sensor Fusion and Generative AI Approaches

另一种选择适用于能够提供多种传感器套件的高端平台，执行传感器融合以减轻一个传感器受到损害的影响。这通常不适合低端无人机，并且不能保证成功[23]。一种更便宜的替代方案是使用生成式人工智能，使用单个廉价传感器生成替代传感器表示。例如，可以使用相机传感器生成红外图像，然后将其融合在一起以实现更鲁棒的环境识别[24]。然而，这些方法需要机载多样化传感器套件或机载运行的强大 GAN，这并不能保证成功。

1.2.3 Adversarial Environmental Perturbations in DRL

第一人称视角 (FPV) 导航问题通常被认为是部分可观察的 [25]，因为在任何给定时间，代理只能看到整个状态的一部分。但是，还必须考虑传感器故障。鲁棒部分可观测 MDP [26] 认为 POMDP 具有不确定的参数。其他方法 [27] 将对手和代理之间的交互视为零和最小最大博弈，并将其定义为概率动作鲁棒 MDP。张等人。[28] 考虑添加对抗性扰动作为状态对抗性 MDP (SA-MDP)。在这个框架中，环境返回的状态可能会受到对手的干扰（对手可能是另一个代理或扰乱状态观察的环境过程），使得观察不确定并导致代理返回的动作可能不是最优的。因为我们认为对手可以是静态的（例如，它是环境的一部分），所以我们更喜欢使用 SA-MDP 框架来解决我们的问题。

在构建鲁棒的强化学习模型时，其中一些工作关注可能影响代理物理特性的物理扰动[29]（例如通过引入不确定的力），而其他工作则考虑对传感器状态的扰动[30]。Korkmaz [31, 32] 认为，与最先进的对抗性和稳健的训练技术相比，普通训练会产生更稳健的策略。哈文斯等人。[33] 提出了一种在对手存在的情况下切换子策略的分层强化学习方法。对抗性训练的应用[34]展示了如何使用零和动作鲁棒强化学习方法来减少空中交通管理场景中的冲突。

1.3 Gap and Novelty

尽管存在关于 DRL 和传感器攻击的研究，但我们还没有发现在学习导航策略期间结合传感器故障对 DRL 性能影响的详细研究。我们的目标是了解传感器故障（自治系统中一种潜在的灾难性故障模式）对 DRL 代理学习导航策略的能力的影响。为此，我们：

- 在 *DRL-Robot- Navigation* 环境上对不同的强化学习算法进行基准测试。
- 研究观测空间（激光雷达和摄像头）对导航能力的影响。

- 进行定量和定性研究，显示对抗性扰动（噪声和传感器故障）对导航任务中 DRL 算法性能的影响。

此外，为了让其他人能够复制我们的工作，我们开源了对 *DRL-Robot-Navigation* 环境的修改，并更新它以适应体育馆 [35] 界面。¹

在本文中，我们在第 2 节中解释了方法，即环境、环境的变化和强化学习模型的选择。我们在第 3 节中介绍了不同算法对环境的基准测试结果、激光雷达和相机噪声研究，以及关于文献的讨论。最后，我们在第 4 节中总结并提出了进一步工作的建议。

2 Methodology

我们构建在 *DRL-Robot-Navigation* 环境 [7] 之上，该环境模拟机器人在 10 m x 10 m 的迷宫中导航，迷宫中充满了静态障碍物。该机器人拥有一套传感器——激光雷达、摄像头和里程计——但在原始论文中，只有其中的一个子集被用作状态观察来训练强化学习模型。原论文使用激光雷达、到目标的距离和到目标的角度，串联在一起作为观察空间，并且没有使用相机。图 1 展示了环境图示，其中显示了 *DRL-Robot-Navigation* 环境以及传感器读数。

由于本研究的重点是研究对抗性传感器扰动并测试不同的传感器套件，因此环境的变化在第 2.1 节中进行了描述。图 2 说明了使用不同模态和不同传感器噪声训练不同 RL 算法（TD3、PPO、PPO LSTM 和 DreamerV3）的基准测试程序。基准测试中使用的强化学习算法在第 2.2 节中描述。训练实验设置，包括超参数，如第 2.3 节所示。评估过程如第 2.4 节所述。

2.1 Changes to the DRL-Robot-Navigation Environment

为了进行我们的实验，*DRL-Robot-Navigation* 环境需要进行一些更改。环境的主要变化是增加了基于视觉的观察空间。为此，从环境中输出机器人的图像，并添加视觉标记来标记目标的位置。在球门所在位置添加一个直径为 0.5 m 的粉色球体，如图 1（左上图）所示。

碰撞系统已更新，与最初的实现一样，它依赖于激光雷达传感器的读数。这不是检测碰撞的可靠方法，并且向激光雷达传感器添加噪声可能会触发碰撞。相反，我们生成一个标志，并通过触发可以订阅的 ROS 主题来检测对象之间的任何物理碰撞。

¹<https://github.com/mazqtpopx/cranfield-navigation-gym>




Fig. 1 *DRL-Robot-Nav Maze* 环境示例 [7]。左上：Gazebo 中呈现的环境的自上而下视图。左下：RGB 相机的视图。右：RViz 离散激光雷达传感器读数、机器人和噪声传感器区域的可视化（蓝色：相机噪声区域，红色：激光雷达噪声区域）。添加粉红色球体（左上角）作为视觉提示，以标记基于愿景的政策的目标。

我们添加了包含传感器噪声的区域：分别针对激光雷达和相机。这些区域是固定大小的矩形，在每集开始时在地图的随机点生成。传感器故障的建模方式将在第 2.1.1 节中进一步描述。

我们更新了奖励系统。最初，智能体因达到目标而获得 100 奖励，因与墙壁碰撞而获得 -100 奖励。否则，返回动作（惩罚不动作的机器人）和距墙壁的最小距离（基于激光雷达观测，如果机器人距墙壁小于 1 m）的函数。首先，我们将奖励标准化在 +1 和 -1 之间。接下来，我们添加了一步的惩罚：大小为 -1 除以最大步数。这样做是为了防止机器人不移动并与其他体育馆环境保持一致的局部最小值[35]。我们还认为惩罚不作为和激光雷达距墙距离的功能是不必要的。相反，我们认为这些项目——不作为和避免障碍——应该在政策方面通过观察而不是奖励塑造来学习。

2.1.1 Modelling Adversarial Sensor Perturbations

自动驾驶汽车通常使用摄像头作为导航的主要传感器，但很少考虑物理传感器攻击。金等人。[36] 对无人机攻击进行审查，包括对相机传感器的激光攻击。他们发现应用后，相机像素会扭曲。这表明相机传感器容易受到




Fig. 2 实验图显示了所提出的实验的过程。环境由干净、相机噪声和激光雷达噪声变体组成。环境以两种方式输出观察结果：激光雷达和摄像头。然后训练多种算法来导航到目标，同时避开障碍物。

物理攻击。相机攻击被建模为完全失败，即相机噪声矩形内部的所有像素都变黑（0）。虽然这没有在物理攻击后明确建模，但它是相机可能的临时故障模式，如图 3(b) 所示。激光雷达攻击通过添加高斯噪声来建模，范围在每个激光雷达点 0-5 米之间。传感器噪声均匀地施加到整个噪声区域。激光雷达传感器扰动如图 3(a) 所示




Fig. 3 激光雷达噪声区域中的机器人示例，由 RViz 可视化。一旦进入红色激光雷达噪声区域，离散激光雷达点就会添加高斯噪声，并且不再提供环境的准确表示。相机噪声区域中的机器人示例，由 RViz 可视化。一旦进入蓝色相机噪声区域，图像输入（如左侧所示）的所有像素都变成黑色 - 这模拟了相机故障。

2.2 Reinforcement Learning Benchmark

以下 RL 方法的基准测试是在 *DRL-Robot-Navigation* 环境中执行的：

- **Twin Delayed DDPG (TD3)** [37] 是一种离策略、无模型的算法，设计用于连续动作空间。它采用两个 Q 值逼近器（批评者）并使用两个 Q 值中较小的一个来更新策略，这有助于减轻高估偏差的问题。TD3 还引入了更新策略网络的延迟，以减少策略更新的方差，并向目标操作添加噪声以鼓励探索。用于训练 TD3 的超参数如表 1 所示。
- **Proximal Policy Optimization (PPO)** [38] 是一种在策略、无模型算法，设计用于连续空间。还使用了 **Recurrent PPO**，它是 PPO 的修改，引入了长短期记忆（LSTM）层 [39]。用于训练 PPO 和循环 PPO 的超参数如表 2 所示。循环架构与 PPO 类似，但在 Actor-Critic 多层感知器之前包含一个 LSTM 层（但在用于摄像机观察的卷积层之后）。
- **DreamerV3** [40] 是一种基于模型的离策略算法，通过结合将输入编码为离散表示的自动编码器，从经验中学习世界模型。它使用循环并预测情节的动态、奖励和连续性。超参数是固定的，因此不需要调整。它已在多种环境中表现优于 PPO，包括 DeepMind Lab 上的导航 [10]。基于此，预计 DreamerV3 在我们的导航问题上应该优于其他算法。使用默认模型。

TD3、PPO 和循环 PPO 的稳定基线 3 [41] 实现用于实验。TD3 和 PPO 的一般设置如图 4 所示，显示了相机和激光雷达观测的网络。对于相机观察，图像最初通过卷积网络以将维度减少到 256 个特征。然后这些特征会被传递到 actor-critic MLP 中。在循环 PPO 的情况下，特征首先通过 LSTM 层，然后再传递给 actor-critic。对于激光雷达，因为它只包含 24 个数据点，所以特征会直接传递给 actor-critic。我们执行：

- 强化学习方法的基准。
- 学习率发现，为每个算法找到最佳 LR，因为它是最敏感的超参数（Dreamerv3 除外，因为它不需要超参数调整）。这如附录所示。
- 研究传感器扰动区域中不同观察空间中代理的性能。




Fig. 4 相机和激光雷达观测网络。在相机观察模型（TD3、PPO、PPO-LSTM）中，图像首先通过卷积层并展平为 256 个特征，以减少输入的维度。然后将这些特征输入到 actor-critic MLP。对于激光雷达观测模型（TD3、PPO），输入已经是低维的，因此 20 个激光雷达读数与到目标的距离、到目标的角度以及之前的操作和 MLP 的输入连接在一起。

Table 1 TD3训练参数（最终值以粗体显示）

Parameter	Value
Learning Rate	0.03 / 0.003 / 0.0003 / 0.00003 (see LR study)
Tau	0.005
Learning Starts (after, steps)	5000
Batch Size	16384 (Lidar), 256 (Camera)
Discount Factor	0.99
Exploration Noise	0.3

Table 2 PPO和PPO LSTM训练参数（最终值以粗体显示）

Parameter	Value
Learning Rate (Lidar)	0.03 / 0.003 / 0.0003 / 0.00003 (see LR study)
Learning Rate (Camera)	0.03 / 0.003 / 0.0003 / 0.00003 (see LR study)
Batch Size	256
Discount Factor	0.99

2.3 Experimental Scenario Settings

实验设置如表 3 所示。激光雷达观测空间由 20 个离散点组成，这些点在机器人周围 1 80° 圆弧上以均匀间隔采集。相机图像为 DreamerV3 生成 160x160 px RGB 图像和 64x 64 px RGB 图像（DreamerV3 的输入要求为 2^2 的幂）。激光雷达噪声是高斯噪声，而相机噪声会导致完全停电。代理位置输入（对于激光雷达

²<https://github.com/danijar/dreamerv3/issues/12>

仅模态)是完全准确的。激光雷达的目标位置是随机的,而相机的目标位置是静态的。步骤之间的时间增量为 0.05 秒 - 这是代理执行操作之间的延迟。请注意,模拟以 4.0 倍实时速度运行,这导致该时间步长为 0.2 秒,即代理实际上以 5 Hz 的速度实时运行。当智能体达到目标时,奖励函数会产生稀疏奖励、撞墙时的惩罚以及每一步的小惩罚以防止不作为。每集的最大步数为 50。

模拟中存在几个影响学习过程的随机参数。正如 Mirowski 等人所表明的那样,随机性起着关键作用。[6]。在他们的模拟中,强化学习智能体在静态小型迷宫中的表现优于人类,但在大型复杂迷宫(具有随机参数,例如随机智能体生成)中表现不佳。*DRL-Robot-Navigation* 和 DeepMind Lab 之间的另一个区别是,我们的环境会惩罚与墙壁的碰撞,从而阻止沿墙策略。

与激光雷达相比,相机策略需要更长的训练时间(超过 50 万步),这超出了本研究的计算预算。为了简化它,目标是在地图中心生成的,而不是随机生成的。机器人仍然以随机位置和方向生成。这类似于 DeepMind 实验室的“静态迷宫”,由 Mirowski 等人测试。他们的“随机目标迷宫”类似于我们在激光雷达实验中测试的随机目标位置(尽管 DeepMind 实验室没有惩罚墙壁碰撞)。

一般来说,除了 DreamerV3 之外,由于观察空间增加,相机策略可能需要更长的时间才能收敛到解决方案:即使在卷积层之后,状态也包含 256 个特征,而激光雷达则包含简单得多的 24 个点(包括之前的动作、到目标的距离和到目标的角度)。

DRL-Robot-Navigation 环境的原始实现随机化机器人的起始位置和方向,以及每集开始时的目标位置。

为了提高相机策略的收敛性,为了更好地理解传感器拒绝效应,我们简化了相机实验的环境。我们将目标的位置固定为始终位于迷宫的中心。这可以减少环境中的随机性,并实现策略的快速收敛。对于激光雷达实验,我们保持目标和机器人的生成位置是随机的。

2.4 Training and Evaluation

2.2 节中描述的强化学习 (RL) 模型使用以下配置和环境进行训练:

- 激光雷达(这包括到目标的距离和角度)。这些模型在各种 0x0 (无噪声) 地图以及具有不同噪声量的地图上进行训练: 3x3、5x5 和 7x7 米噪声区域。
- 仅相机,静态目标。这些模型在各种 0x0 (无噪声) 地图以及具有不同噪声量的地图上进行训练: 3x3、5x5 和 7x7 米噪声区域。

除非另有说明,相机配置包含一个静态目标,以实现更好的收敛,如第 2.3 节所述。然后在 2.4 节中指定的地图上评估每个模型,但通常这包括在每个模型上进行测试

Table 3 仿真参数

	<i>Parameter details</i>
Lidar Measurements	180° LiDAR data discretized into 20 intervals
Camera Measurements	150px x 150px RGB image 64px x 64px RGB image (Dreamer)
Attack Type Lidar	Gaussian noise added to each discrete point
Attack Type Camera	Complete failure
Agent Position	Fully accurate (ground truth from Simulation)
Goal Position	Lidar: random Camera: static
Delay between steps	0.05 seconds
Reward function	$R(s, a) = \begin{cases} 1, & \text{goal reached} \\ -1, & \text{collision} \\ -1/50, & \text{otherwise} \end{cases} \quad (1)$
Max. Episode Steps	50

不同噪声大小的环境：0x0、3x3、5x5、7x7。在某些情况下，模型在地图的简化版本上进行评估，如第 2.4 节所述。

图 5 显示了激光雷达和相机环境的训练和评估设置的概要。

2.4.1 Camera Evaluation Maps

为了评估相机策略，使用两个不同的地图：


- *DRL-Robot-Navigation* 地图（与训练相同）。
- 简化的 *DRL-Robot-Navigation* 地图没有障碍物，如图 6 所示。目标始终静止在中心。噪声区域在地图的中心是静态的。

使用简化地图的目的是为了更好地理解策略的行为。当障碍物被清除后，剩下的唯一任务就是穿过传感器禁区到达目标。由于噪音是静态的，它总是会阻碍目标。在这个评估任务中，我们忽略了智能体避开障碍物的能力，而是关注智能体是否学会了穿过噪声区域。简化地图仅用于评估，从不用于策略训练。默认情况下，使用 *DRL-Robot-Navigation* 进行评估。简化地图的使用在结果部分中明确指定。


3 Results

进行了多项实验来对环境中不同的 DRL 算法进行基准测试，并了解不同的训练方案（普通与对抗）如何

Lidar Training/Evaluation



Camera Training



Camera Evaluation




Fig. 5 激光雷达和摄像头传感器的训练和评估场景。对于激光雷达场景，模型在各种 0x0（普通）地图和具有不同传感器扰动量的地图上进行训练：3x3、5x5 和 7x7 米传感器噪声区域。这些区域包含添加到传感器读数中的高斯噪声。然后在同一张地图上评估这些经过训练的策略。同样，对于相机场景，模型在各种 0x0（普通）地图和具有不同传感器扰动量的地图上进行训练：3x3、5x5 和 7x7 米传感器拒绝区域。在这些区域内，相机传感器完全失效（所有像素变成黑色）。模型在默认地图上进行训练，中间有一个静态目标，蓝色区域是相机完全失效的区域。然后在具有不同程度噪声的默认地图上评估这些策略。第二次评估是在没有障碍物的地图上进行的，以更好地理解传感器拒绝区域中学到的策略。

影响模型在不同环境扰动大小的环境中的性能。虽然第 3.1 节对激光雷达和相机模式的初始训练进行了比较，但结果部分的其余部分根据模式分为两部分。第一部分在第 3.2 节中介绍了 PPO 和 TD3 在定量结果方面的表现，然后在第 3.3 节中通过了解政策遵循的路径以及它们在不同培训制度下的差异来定性。

摄像机观察部分首先在第 3.4 节中对普通环境下的不同算法进行直接训练比较，然后在第 3.5 节中对具有传感器拒绝的不同模型进行定量基准，并在第 3.6 节中在无障地图对模型进行评估。最后，第 3.7 节中的文献讨论了结果。




Fig. 6 *DRL-Robot-Navigation* 地图的简化版本，没有障碍物，中心有一个静态目标，周围有一个传感器扰动区域。(a) 显示 3x3 传感器拒绝区域，(b) 显示 5x5 传感器拒绝区域，(c) 显示 7x7 传感器拒绝区域。机器人在地图周围的随机位置和方向生成。该地图仅用于评估相机策略，而不是激光雷达策略。




Fig. 7 使用 PPO 进行激光雷达和相机的模态研究。摄像机针对静态和随机目标进行训练。每个模型都经过 500,000 步的训练。

3.1 Modality Study

图 7 所示的模态研究显示了 PPO 算法在激光雷达（具有随机目标）、具有静态目标的相机和具有随机目标的相机上的模型性能差异。具有静态目标的激光雷达和摄像机可以快速收敛到接近最大剧集奖励的解决方案。具有随机目标的相机不会以给定的步数收敛到解决方案。当我们尝试了解传感器扰动的影响时，我们将继续使用具有静态目标的相机进行相机噪声实验。

3.2 Lidar Navigation with Noise

尽管 2.2 节提出了不同的算法，但我们无法找到合适的学习率来使 PPO-LSTM 收敛，如附录 A3 所示。虽然可以在激光雷达观测空间上训练 DreamerV3，但对于如此小的观测空间来说，它是一个大型模型，我们没有发现它的性能比其他模型有所提高。因此，本节仅比较 TD3 和 PPO。




Fig. 8 激光雷达噪声区域研究，用于在无噪声的默认环境下训练的算法。然后在默认环境（具有随机目标）上评估算法，并改变噪声区域大小（如 x 轴所示）。评估进行了 100 次并重复 5 次以建立标准偏差。

图8显示了TD3和PPO在默认地图上使用激光雷达观测空间的评估结果。这些算法在 0x0（普通）地图上进行训练，并在激光雷达噪声区域增加的环境中进行评估：0x0（普通）、3x3、5x5 和 7x7 - 指的是噪声区域矩形的大小（以米为单位）。TD3 在不同的评估中均优于 PPO。它在 0x0 评估场景上的平均成功率为 87.2%，而 PPO 的平均成功率为 83.0%。两个模型之间的性能差异通常随着噪声区域尺寸的增大而增大。当对 7x7 噪声区域大小进行评估时，TD3 达到 51.4%，而 PPO 达到 35.2%。

图 9 显示了 TD3 和 PPO 的相同评估结果，算法在 3x3 噪声图上进行训练。在这些结果中，PPO 在整个评估中与 TD3 的性能非常匹配，在较大的噪声区域尺寸上优于 TD3。在普通 0x0 场景中进行评估时，TD3 的平均成功率为 69.6%，PPO 的平均成功率为 68.0%。这是在普通 0x0 环境中训练的模型的性能下降。在 7x7 场景下进行评估时，PPO 模型的平均成功率为 54.0%。这是对在普通 0x0 环境上训练的 PPO 模型的改进，并且略优于在相同方案上训练的 TD3 模型。与在 0x0 环境中训练的 TD3 模型相比，在 3x3 噪声环境中训练的 TD3 模型在所有评估场景中的性能均有所下降。




Fig. 9 激光雷达噪声区域研究，用于在具有随机 3x3 噪声区域和随机目标的默认环境下训练的算法。然后在具有不同噪声区域大小的同一张地图上评估算法，如 x 轴所示。评估进行了 100 次并重复 5 次以建立标准偏差。

3.3 Lidar Noise Training Regimes, Qualitative Results

如第 3.2 节所示，训练制度影响算法的评估性能。为了更好地理解激光雷达特定策略的行为，我们可以更仔细地研究每种算法在噪声环境中训练的效果，并在评估过程中研究机器人的轨迹。




Fig. 10 在不同激光雷达噪声方案上训练的 PPO 策略在具有不同噪声区域大小的默认地图（具有随机目标）上进行评估。这些策略针对 100 个步骤进行了 5 次评估，该图显示了这 5 次重复运行的平均值和标准误差。

图 10 显示了在默认地图上评估的不同激光雷达噪声方案上训练的 PPO 策略。结果表明，在没有噪声的地图上进行评估时，普通 PPO (0x0) 表现最好，平均成功率为 83%。在 5x5 噪声图上进行评估时，在噪声环境（PPO 3x3、5x5 和 7x7）上训练的策略开始优于普通策略。虽然随着环境中添加更多噪声，噪声策略不会显著降低性能，但在 0x0 no 上进行评估时，与普通模型相比，它们的性能持续下降。

噪声环境。这可能是由于遵循风险较高的策略的嘈杂策略，牺牲了防撞能力以提高导航性能。为了更好地理解这一点，我们可以通过绘制评估运行的路径、崩溃和成功导航来定性研究评估运行。




Fig. 11 评估过程中生成的 100 个路径图是通过在 0x0 噪声图 (a) 上评估的普通策略 (PPO 0x0)、在 7x7 噪声图 (b) 上评估的普通策略 (PPO 0x0)、在 0x0 噪声图 (c) 上评估的噪声策略 (PPO 3x3) 以及在 7x7 噪声图 (d) 上评估的噪声策略 (PPO 3x3) 进行评估。红点表示碰撞，绿点表示成功导航至目标。

图 11 显示了在两个不同的评估图（0x0 和 7x7）上评估 2 个不同策略（PPO 0x0 和 PPO 3x3）期间生成的 100 个路径图。图 11 (a) 显示了在无噪声图上评估的普通 PPO。在图 11(b) 中，在具有随机 7x7 噪声区域的地图上评估相同的策略。该政策无法达到目标，并且绩效显着下降（从 79 次成功降至 26 次成功）。它还表明，在一半的运行中，该策略达到了最大事件时间步长限制，并且既没有崩溃也没有达到目标。与无噪声地图上的评估相比，路径往往要短得多，这表明该策略更倾向于遵循“安全”策略，即在噪声区域内不做任何事情。相比之下，当在小噪声（3x3随机区域）上进行训练并在无噪声上进行评估时，如图11 (c) 所示，整体性能从79次成功下降到69次，崩溃次数从21次增加到31次。但是，当在7x7噪声区域上进行评估（如图11 (d) 所示）时，该策略不再遵循“安全”策略，而是选择“风险更高”的方法。这将成功事件的数量从 26 次增加到 49 次，但也将崩溃次数从 24 次增加到 51 次。

总的来说，安全策略并没有带来更好的整体性能，因为达到最大步数的奖励是 -1，就像崩溃一样，它是 -1。但是，由于有风险的策略会导致更成功的运行，从而产生正的 +1 奖励，因此对于噪声评估图而言，它是更优化的策略。一个有趣的观察结果是，当在噪声地图上进行训练时，在 PPO 运行中始终出现风险较高的策略，而当未对任何噪声进行训练时，该策略会遵循一种更安全的策略，即在不确定其传感器读数时让事件运行完，如图 10 所示。这可能是由于噪声传感器读数超出了在非噪声环境上训练的策略之前观察到的域。




Fig. 12 TD3 策略在不同激光雷达噪声方案上进行训练，并在具有不同噪声区域大小的默认地图（具有随机目标）上进行评估。这些策略针对 100 个步骤进行了 5 次评估，该图显示了这 5 次重复运行的平均值和标准误差。

图12同样显示了TD3策略。与 PPO 训练方案不同，TD3 通常不会从噪声场景的训练中受益，并且在无噪声图上训练的默认策略在所有评估场景中表现最佳。

3.4 Algorithm Training Comparison (Camera Observation)

如 2.2 节所述，在 *DRL-Robot-Navigation* 环境上训练不同的 RL 方法：TD3、PPO、Recurrent PPO（或 PPO-LSTM）和 DreamerV3。




Fig. 13 训练过程中不同算法的收敛性比较。DreamerV3 使用随机目标进行训练，而其他模型则使用中心的静态目标进行训练（使得 DreamerV3 的收敛更加复杂）。

图 13 显示了不同算法训练期间 500,000 个训练步骤的平均情节奖励。对于静态目标场景，TD3、PPO 和 PPO-LSTM 快速收敛到一个解决方案，每一个都在不到 100,000 步的时间内达到 0.5 的平均奖励。唯一能够学习导航到随机目标的模型是 DreamerV3。相比之下，即使走了 50 万步，PPO 也无法学会导航。尽管如此，为了更好地了解噪声对训练的影响，相机策略将使用静态目标。

3.5 Camera Navigation with Sensor Denial

图14显示了使用相机观察空间的不同算法TD3、PPO、PPO-LSTM和DreamerV3的评估结果。这些算法在普通 0x0 地图上进行训练，并在增加相机拒绝区域的环境中进行评估：0x0（传感器拒绝）、3x3、5x5 和 7x7 - 指传感器拒绝区域的矩形大小（以米为单位）。在 0x0 评估场景中，DreamerV3 实现了最高的平均成功率 90.8%，TD3 实现了类似的性能 88.8%。PPO-LSTM 排名第三，平均成功率为 82.2%，PPO 表现最差，平均成功率为 71.6%。在 3x3 评估场景中，模式保持不变，DreamerV3 达到了最高平均值 73.2%（标准误差更大，为 6.8），TD3 紧随其后，为 68.4%，PPO-LSTM 第三




Fig. 14 相机噪声区域研究，用于在没有传感器拒绝的普通环境下训练的算法。然后在噪声区域大小不断变化的普通环境中评估算法，如 x 轴所示。评估进行了 100 次并重复 5 次以建立标准偏差。

最后是 PPO。5x5 和 7x7 的评估场景显示所有算法的性能都严重下降。




Fig. 15 研究了相机噪声，用于在具有 3x3 传感器拒绝区域的默认环境中训练的算法。然后在默认环境下评估算法，并改变传感器拒绝区域大小（如 x 轴所示）。评估进行了 100 次并重复 5 次以呈现平均值和标准误差。

类似地，图 15 显示了在具有随机 3x3 拒绝区域的地图上训练的算法的评估结果。在 0x0 场景中进行评估时，出现了类似的模式，DreamerV3 实现了 86.4% 的最高平均成功率（尽管与在干净场景中训练时的 90.8% 相比，性能有所下降）。TD3 位居第二，为 82.4%，PPO 和 PPO-LSTM 表现最差，分别为 71.0% 和 72.4%。与在干净（即没有传感器拒绝区域）环境中训练的策略相比，所有策略的性能均有所下降。

在 3x3 场景中进行评估时，DreamerV3 表现最佳，平均成功率达到 80.6%。这是对普通模型（73.2%）的改进。TD3 平均成功率为 73.2%，PPO 为 69.2%，PPO-LSTM 垫底，为 58.6%。同样地，

TD3 和 PPO 也显示出相对于普通型号的改进。PPO-LSTM 是唯一一个没有报告比普通模型有改进的模型。

所有模型都报告在 5x5 和 7x7 噪声区域图上的评估性能有所提高（与在环境中无噪声的情况下训练的模型相比），这表明对场景中的某些噪声进行训练通常会提高在有噪声的评估场景中的评估性能。尽管如此，这些改进并没有那么显著，以至于模型无法可靠地实现目标。在具有传感器拒绝区域的 3x3 场景中训练模型的缺点是，在 0x0 场景中进行评估时，这些模型似乎会出现性能下降的问题。

3.6 Camera Navigation with Sensor Denial (No Obstacle Map)

3.5 节表明，训练制度对传感器拒绝区域的政策行为有影响。为了更好地理解这种行为，我们在简化的无障碍地图上对它们进行评估，如第 2.4 节所述。




Fig. 16 相机噪声区域研究，用于在具有 0x0 噪声的默认环境下训练的算法。然后在具有变化的噪声区域大小的简化地图上评估算法，如 x 轴所示。对 100 集进行了评估。

图 16 显示了使用相机观察空间的不同算法 TD3、PPO、PPO-LSTM 和 DreamerV3 的评估结果。这些算法在普通 0x0（无传感器拒绝）默认地图上进行训练，并在简化的无障碍物地图上进行评估，其中位于地图中心的静态相机拒绝区域不断增加：0x0（无传感器拒绝）、3x3、5x5 和 7x7 - 指的是传感器拒绝区域的矩形大小（以米为单位）。所有四个模型都表现出类似的行为，即在 0x0 评估的几乎所有场景中都成功导航，但在引入任何噪声时始终失败（少数成功可能是由于在目标附近生成而导致的）。

同样，图 17 显示了在具有随机 3x3 噪声区域的默认地图上训练的不同算法的评估结果。0x0 评估没有显著变化，TD3、PPO 和 DreamerV3 在 100 次中仍然成功导航到目标 98、98 和 96 次。对于 3x3 评估，TD3 达到目标 74 次，PPO 71 次，PPO-LSTM 66 次，DreamerV3 表现最好。




Fig. 17 研究相机噪声，用于在具有 3x3 噪声的默认环境下训练的算法。然后在具有变化的噪声区域大小的简化地图上评估算法，如 x 轴所示。对100集进行了评估。

与 87 次。与在 0x0（无噪声）环境中训练的模型相比，这是一个显著的改进 - 这表明策略已经学会在存在噪声的情况下导航到目标。在 5x5 和 7x7 场景中进行评估时，3x3 训练的模型还显示出比 0x0 训练的模型有性能提升。然而，它们并没有达到很高的成功率 (90+)，这表明政策真正解决了这些场景。




Fig. 18 针对不同噪声状况进行训练的 PPO 政策在具有不同噪声区域大小的简化地图上进行评估。

图 18 显示了在无障碍地图上评估的不同相机噪声方案上训练的 PPO 策略。结果表明，在 0x0 场景下评估时，PPO (0x0) 和 PPO (3x3) 表现最好，分别实现了 99 次和 98 次成功。在任何噪声图上进行评估时，PPO (0x0) 无法导航到目标。PPO (5x5) 和 PPO (7x7) 在 0x0 评估中均未能成功导航，这表明过多的噪声阻碍了这些模型的学习。

图 19 显示了在两个不同的评估图（0x0 和 3x3 静态）上评估 2 个不同策略（PPO 0x0 和 PPO 3x3）期间生成的 100 个路径图。




Fig. 19 在 0x0 地图 (a) 上评估的普通策略 (PPO 0x0) 评估期间生成的 100 个路径图, 在 3x3 传感器拒绝地图 (b) 上评估的普通策略 (PPO 0x0), 在 0x0 传感器拒绝地图 (c) 上评估的对抗训练 (PPO 3x3), 以及在 3x3 传感器拒绝地图 (d) 上评估的对抗训练 (PPO 3x3)。红点表示碰撞, 绿点表示成功导航至目标。蓝色区域显示传感器拒绝区域。

传感器禁区、静态目标位于中心且不存在任何障碍物)。图 19(a) 显示了在 0x0 图上评估的普通 PPO。在图 19(b) 中球门周围具有静态 3x3 噪声区域的地图上评估相同的普通策略。该策略无法实现目标, 并且表现显着下降 (从 100 次成功减少到 5 次成功)。当机器人进入噪声区域时, 摄像头失效,

然后机器人停止移动。这可以看作是许多路径在蓝色噪声区域内结束并且不再继续。

相比之下，当使用环境中存在的 3x3 随机区域进行对抗性训练并在 3x3 地图上进行评估（如图 19（d）所示）时，成功的次数增加到 75。当在蓝色传感器拒绝区域内时，智能体只是简单地绕圈移动，如蓝色区域中的路径轨迹所示。这不是一种在环境中存在障碍物时可靠的导航方式，但当传感器拒绝区域中不存在障碍物时，这种方式会成功。该策略利用场景的奖励结构，选择穿过传感器拒绝区域的高风险策略。因此，就像图 11 中所示的激光雷达示例一样，这些政策已经学会了在传感器读数不确定时盲目导航的高风险策略。

由于我们正在简化地图上进行评估，因此不存在任何障碍。显然，一旦进入传感器拒绝区域，政策就无法避免障碍，并且故意不在这些结果中反映出来，以便了解传感器拒绝区域中的政策行为。尽管如此，由于模型是在默认地图上进行训练的，因此它们已经学会了在存在障碍物的传感器拒绝区域时采取危险的行动。这可能意味着，由于环境的奖励塑造，政策采取高风险行动会获得更大的奖励。然而，这只适用于环境中少量的传感器拒绝区域，如图 18 所示，因为大量的噪声会导致无法学习基本的导航行为。

3.7 Discussion

相机导航方面总体表现最佳的是 DreamerV3。当在 0x0 和 3x3 环境上进行训练时，DreamerV3 在 0x0 和 3x3 噪声区域评估的相机观察方面始终优于其他模型（图 14 和 15）。这可能是由于 DreamerV3 具有与其他模型不同的结构，并且由于自动编码器结构而构建了世界模型。我们假设它可能能够克服由于自动编码器/循环结构而导致的传感器拒绝区域。虽然它在 3x3 环境中训练和评估时确实优于其他模型（图 14 中的平均值达到 80.6%），但在无噪声环境中训练和评估时仍然不符合 90.8% 的基线性能。DreamerV3 也是唯一一个学会使用仅相机观察空间在 500,000 步内导航到随机目标的模型，如第 3.4 节所示。其他模型要么需要激光雷达策略（其中包含有关目标距离和角度的信息），要么需要静态目标才能使用相机观察空间收敛到解决方案。DreamerV3 使用起来也很方便，因为它不需要任何超参数调整。激光雷达模式的最佳性能（介于 TD3 和 PPO 之间）是 TD3。在不同的评估中，0x0 训练的 TD3 模型通常优于 PPO 的大多数变体。

在第 3.2 节和第 3.6 节中，我们了解到，环境中存在一些噪声的训练策略会带来一个有趣的结果：这些策略在实现目标方面更成功，但当传感器读数不确定或完全否认时，也会采取更多高风险的行动，这可能会导致更频繁地与障碍物相撞——在我们的场景中这是一个终止事件。这是训练的局限性

针对安全关键场景的强化学习策略。训练它们在不确定的情况下最大化奖励并实现目标可能会导致策略学习选择被视为奖励的行动并可能导致实现奖励，即使这些行动可能会导致灾难性的情况。

Korkmaz [31] 报告称，经过对抗性训练的政策更容易受到诸如以下方面的变化的影响：比普通训练过的亮度或模糊度更高。虽然我们没有考虑对抗性学习算法（Korkmaz 使用基于 SA-MDP 和 RADIAL 算法的 SA-DDQN，而我们只在具有对抗性扰动的环境中训练我们的模型），但这可以映射到我们的问题，因为与普通 PPO (0x0) 相比，我们的噪声训练策略（例如 3x3 PPO）会导致大量崩溃，并且在 0x0 评估上的稳健性较差。

米罗斯基等人。[6]进行了一项类似的研究，其中包括静态迷宫和大型随机迷宫。这些相当于静态目标（我们使用相机执行）和随机目标（我们使用激光雷达执行）。在他们的论文中，使用递归的算法优于非循环算法。我们在结果中没有看到这样的趋势，并且 PPO-LSTM 通常表现不佳（忽略同样经常出现的 DreamerV3）。这是令人惊讶的，因为导航是部分可观察的马尔可夫决策过程（MDP），因此，策略应该受益于记忆。

4 Conclusion and Further Work

这项研究展示了常见强化学习算法如何在 *DRL-Robot-Navigation* 环境中以不同方式（相机和激光雷达）执行的定量结果，以及训练和评估对包含噪声和传感器遮挡区域的环境的不同影响。我们观察到，与在普通无噪声环境中训练的模型相比，在噪声环境中训练 DRL 模型创建的策略通常在噪声环境中表现更好。然而，我们发现，当出现嘈杂或错误的观察时，这些策略会选择风险更大的行动：这些行动可能会成功导航到目标，但也会与另一个物体发生碰撞。虽然这些模型通过定量指标获得了更好的性能，但从安全关键场景的角度来看，这种行为是不可接受的，并且表明需要更强大的强化学习方法，以适应场景中的噪声或传感器中断。因此，我们开源了在 *DRL-Robot-Navigation* 之上构建的环境，以使其他研究人员能够评估他们在这类场景下的模型性能。这里给出的结果应该作为未来有关如何处理故障传感器策略的任何研究的基准。虽然我们对激光雷达的高斯噪声和相机中断进行了评估，但也应该集成不同的扰动（例如[32]研究诸如压缩伪影、亮度和对比度以及相机观察的模糊等变换）。我们认为，自动编码器的工作可能会导致识别传感器故障，并有可能作为备份，能够在传感器中断的情况下填补空白。还应该研究传感器融合策略。分层强化学习可以带来更好的性能（正如 Havens 等人提出的[33]），因为它允许顶层检测对手。这可能会导致

在有噪音的任务中表现更好，因为局部目标可能会在情节的过程中发生变化——从导航到目标到摆脱噪音。

最后，我们建议对环境进行进一步的开发，包括环境交互以及更复杂的传感器攻击模型。

Appendix A Learning Rate Sensitivity

由于算法（DreamerV3 除外）对学习率敏感，因此我们最初执行学习率研究 - 然后我们继续使用学习率。




Fig. A1 TD3 学习率发现（激光雷达）。

图 A1 显示了使用激光雷达观测空间的 TD3 算法的学习率发现。0.0003 和 0.00003 值都收敛到大约 0.5 集奖励的最大值，但 0.00003 似乎收敛得更快。

图 A2 显示了使用激光雷达观测空间的 PPO 算法的学习率发现。值 0.003 似乎比 0.0003 收敛得更快的最佳值。

图 A3 显示了使用激光雷达观测空间的 PPO LSTM 算法的学习率发现。没有实现明显的收敛——这令人惊讶，因为我们期望递归网络能够解决这个问题。没有复发的 PPO 在激光雷达观测空间中表现得更好，如图 A2 所示。

图 A4 显示了使用相机观察空间的 PPO LSTM 算法的学习率发现。值 0.0003 是唯一收敛到解的值。我们将在 PPO 和 PPO LSTM 相机运行中使用这个值 0.0003。

Supplementary information. 修改后的 *DRL-Robot-Navigation* 环境可在 <https://github.com/mazqtpopx/cranfield-navigation-gym> 获取。




Fig. A2 PPO 学习率发现（激光雷达）。




Fig. A3 PPO LSTM 学习率发现（激光雷达）。

Acknowledgements. MW 和 PC 的这项工作得到了 Leonardo UK 和克兰菲尔德大学的支持，WG 和 AT 得到了 EPSRC TAS-S: 值得信赖的自治系统: 安全性 (EP/V02 6763/1) 的支持。

Declarations

- 资助：这项与 MW 和 PC 相关的工作得到了 Leonardo UK 和克兰菲尔德大学的支持，WG 和 AT 得到了 EPSRC TAS-S: 值得信赖的自治系统: 安全性 (EP/V026763/1) 的支持。
- 利益冲突/利益竞争 不适用
- 道德批准和同意参与：不适用




Fig. A4 PPO LSTM 学习率发现（相机）。

- 同意发表：不适用
- 数据可用性：不适用
- 材料可用性：不适用
- 代码可用性：代码可用 <https://github.com/mazqtpopx/cranfield-navigation-gym>。
- 作者贡献：所有作者都对研究构思和设计做出了贡献。通过MW和PC进行材料准备、数据收集和分析。该手稿的初稿由 MW 撰写，所有作者都对该手稿的先前版本发表了评论。所有作者阅读并批准了最终手稿。

References

- [1] Krizhevsky, A., Sutskever, I., Hinton, G.E.: 使用深度卷积神经网络进行 ImageNet 分类。见：神经信息处理系统的进展，卷。 25. Curran Associates, Inc. (2012)。 https://papers.nips.cc/paper_files/paper/2012/hash/c399862d3b9d6b76c8436e924a68c45b-Abstract.html 访问时间：2023-08-01 [2] Deng, J., Dong, W., Socher, R., Li, L.-J., Kai Li, Li Fei-Fei: ImageNet: 大规模分层图像数据库。见：2009 年 IEEE 计算机视觉和模式识别会议，第 248-255 页。IEEE，佛罗里达州迈阿密 (2009)。 <https://doi.org/10.1109/CVPR.2009.5206848>。 <https://ieeexplore.ieee.org/document/5206848/> 访问时间：2021-07-21 [3] He, K., Zhang, X., Ren, S., Sun, J.: 图像识别的深度残差学习。arXiv: 1512.03385 [cs] (2015)。arXiv : 1512.03385。访问时间：2021 年 7 月 10 日

- [4] 姆尼赫, .V Kavukcuoglu, K., Silver, D., Rusu, A.A., Veness, J., 埃勒马尔, M.G.,

- Graves, A., Riedmiller, M., Fidjeland, A.K., Ostrovski, G., Petersen, S., Beattie, C., Sadik, A., Antonoglou, I., King, H., Kumaran, D., Wierstra, D., Legg, S., Hassabis, D.: 通过深度强化学习实现人类水平的控制。自然 **518**(7540), 529–533 (2015) <https://doi.org/10.1038/nature14236>。访问时间: 2022 年 12 月 10 日
- [5] Walker, O., Vanegas, F., Gonzalez, F., Koenig, S.: 室内环境中无人机导航的深度强化学习框架。见: IEEE 航空航天会议, 第 1-14 页 (2019 年)。 <https://doi.org/10.1109/AERO.2019.8742226>
- [6] Mirowski, P., Pascanu, R., Viola, F., Soyer, H., Ballard, A.J., Banino, A., Denil, M., Goroshin, R., Sifre, L., Kavukcuoglu, K., Kumaran, D., Hadsell, R.: 学习在复杂环境中导航。arXiv. arXiv: 1611.03673 [cs] (2017)。 <http://arxiv.org/abs/1611.03673> 访问时间: 2022 年 10 月 17 日
- [7] Cimurs, R., Suh, I.H., Lee, J.H.: 通过深度强化学习进行目标驱动的自主探索。arXiv. arXiv: 2103.07119 [cs] (2021)。 <http://arxiv.org/abs/2103.07119> 访问时间: 2023-10-19
- [8] Wisniewski, M., Ona, I.G., Chatzithanos, P., Guo, W., Tsourdos, A.: 对抗性传感器攻击下动态迷宫环境中的自主导航。见: 2024 年无人机系统国际会议 (ICUAS), 第 881–886 页 (2024)。 <https://doi.org/10.1109/ICUAS60882.2024.10557088>。国际标准期刊号: 2575-7296。
<https://ieeexplore.ieee.org/document/10557088/?arnumber=10557088> 访问时间: 2024 年 8 月 23 日
- [9] 朱凯, 张涛: 基于深度强化学习的移动机器人导航: 综述。清华科技 **26**(5), 674–691 (2021) <https://doi.org/10.26599/TST.2021.9010012>。会议名称: 清华科技。访问时间: 2024年8月27日
- [10] Beattie, C., Leibo, J.Z., Teplyaev, D., Ward, T., Wainwright, M., Küttler, H., Lefrancq, A., Green, S., Valdés, V., Sadik, A., Schrittwieser, J., Anderson, K., York, S., Cant, M., Cain, A., Bolton, A., Gaffney, S., King, H., Hassabis, D., Legg, S., Petersen, S.: DeepMind 实验室。arXiv. arXiv: 1612.03801 [cs] (2016)。 <http://arxiv.org/abs/1612.03801> 访问时间: 2023-05-19
- [11] Kempka, M., Wydmuch, M., Runc, G., Toczek, J., Jaśkowski, W.: ViZDoom: 基于 Doom 的视觉强化学习人工智能研究平台。arXiv. arXiv: 1605.02097 [cs] (2016)。 <http://arxiv.org/abs/1605.02097> 访问时间: 2022 年 12 月 10 日
- [12] Mnih, V., Badia, A.P., Mirza, M., Graves, A., Lillicrap, T.P., Harley, T., Silver, D., Kavukcuoglu, K.: 深度强化学习的异步方法。arXiv. arXiv: 1602.01783 [cs] (2016)。 <http://arxiv.org/abs/1602.01783> 访问时间: 2022 年 10 月 24 日

- [13] Kaufmann, E., Bauersfeld, L., Loquercio, A., Müller, M., Koltun, V., Scaramuzza, D.: 使用深度强化学习的冠军级无人机竞赛。自然 **620**(7976), 982–987 (2023) <https://doi.org/10.1038/s41586-023-06419-4>。编号: 7976 出版商: 自然出版集团。访问时间: 2023年9月10日
- [14] Polvara, R., Patacchiola, M., Sharma, S., Wan, J., Manning, A., Sutton, R., Cangelosi, A.: 通过深度强化学习实现无人机自主着陆的端到端控制。见: 国际无人机系统会议 (ICUAS) (2018)
- [15] Chen, J., Li, S.E., Tomizuka, M.: 具有潜在深度强化学习的可解释的端到端城市自动驾驶。IEEE 智能交通系统汇刊 **23**(6) (2022)
- [16] Pasukonis, J., Lillicrap, T., Hafner, D.: 评估 3D 迷宫中的长期记忆。arXiv. arXiv: 2210.13383 [cs] (2022)。 <http://arxiv.org/abs/2210.13383> 访问时间: 2024-04-24
- [17] Lample, G., Chaplot, D.S.: 用深度强化学习玩 FPS 游戏。arXiv. arXiv: 1609.05521 [cs] (2018)。 <http://arxiv.org/abs/1609.05521> 访问时间: 2022 年 10 月 14 日
- [18] 罗成, 杨S.X.: 一种用于未知环境下实时并发地图构建和全覆盖机器人导航的仿生神经网络。IEEE 神经网络汇刊 **19**(7), 1279–1298 (2008) <https://doi.org/10.1109/TNN.2008.2000394>
- [19] al., M.C.: 使用液体神经网络实现分布式鲁棒飞行导航。科学机器人 **8** (2023)
- [20] Sajjadi, S., Bittick, J., Janabi-Sharifi, F., Mantegh, I.: 一种用于室内无人机定位的鲁棒自适应传感器融合方法。见: 国际无人机系统会议 (ICUAS) (2023 年)
- [21] Negru, S.A., Geragersian, P., Petrunin, I., Guo, W.: 采用混合联合融合架构的弹性多传感器无人机导航。传感器 **24** (2023)
- [22] 刘成, 张刚, 郭伟, 何瑞: 基于卡尔曼预测的车载自组织网络邻居发现及其对路由协议的影响。IEEE 智能交通系统汇刊 **21**(1), 159–169 (2020) <https://doi.org/10.1109/TITS.2018.2889923>
- [23] Bae, S., Han, D., Park, S.: 自动驾驶激光雷达和摄像头融合的新方法。见: IEEE 国际信息与通信人工智能会议 (2023)

[24]Kacker, T.、Perrusquia, A.、Guo, W.: 使用生成对抗网络进行无人机野火检测的多光谱融合。见: IEEE 国际。信息与通信人工智能会议 (2023)

[25] Spaan, M.T.J.: 部分可观察的马尔可夫决策过程。见: Wiering, M.、Otterlo, M. (编辑)《强化学习: 最先进的技术》, 第 387-414 页。施普林格, 柏林, 海德堡 (2012) 。 https://doi.org/10.1007/978-3-642-27645-3_12 .
https://doi.org/10.1007/978-3-642-27645-3_12 访问时间: 2024 年 10 月 12 日

[26] Osogami, T.: 鲁棒部分可观察马尔可夫决策过程。见: 第 32 届国际机器学习会议论文集, 第 106-115 页。PMLR (2015) 。国际标准期刊号: 1938-7228。
<https://proceedings.mlr.press/v37/osogami15.html> 访问时间: 2024 年 10 月 12 日

[27] Tessler, C.、Efroni, Y.、Mannor, S.: 动作鲁棒强化学习及其在连续控制中的应用。见: 第 36 届国际机器学习会议论文集, 第 6215-6224 页。PMLR, ??? (2019) 。 ISSN: 2640-3498。 <https://proceedings.mlr.press/v97/tessler19a.html> 访问时间: 2024 年 3 月 4 日

[28] 张 H.、陈 H.、肖 C.、李 B.、刘 M.、Boning, D.、谢 C.-J.: 针对状态观测的对抗性扰动的鲁棒深度强化学习。见: 神经信息处理系统的进展, 卷。33, 第 21024–21037 页。Curran Associates, Inc. (2020)。
https://proceedings.neurips.cc/paper_files/paper/2020/hash/f0eb6568ea114ba6e293f903c34d7488-Abstract.html 访问时间: 2024 年 10 月 9 日

[29] Pinto, L.、Davidson, J.、Sukthankar, R.、Gupta, A.: 鲁棒对抗性强化学习。arXiv. arXiv: 1703.02702 [cs] (2017) 。 <http://arxiv.org/abs/1703.02702> 访问时间: 2024-09-30

[30] Korkmaz, E.: 神经策略中的对抗性训练块泛化。国际学习表征会议 (ICLR) 现实世界中鲁棒可靠的机器学习研讨会, (2021 年)

[31] Korkmaz, E.: 对抗性鲁棒深度强化学习需要重新定义鲁棒性。AAAI 人工智能会议论文集 **37**(7), 8369–8377 (2023) <https://doi.org/10.1609/aaai.v37i7.26009> 。访问时间: 2024年9月28日

[32] Korkmaz, E.: 理解和诊断深度强化学习。arXiv. arXiv: 2406.16979 [cs] (2024) 。 <http://arxiv.org/abs/2406.16979> 访问时间: 2024-09-28

[33] Havens, A.J.、Jiang, Z.、Sarkar, S.: 未知对手存在下的在线稳健政策学习。arXiv. arXiv: 1807.06064 [cs, 统计] (2018) 。 <http://arxiv.org/abs/1807.06064> 访问时间 2024-10-09

- [34] Panda, D.K., Guo, W.: 针对冲突引起的欺骗的空中机动去冲突的行动鲁棒强化学习。IEEE 智能交通系统汇刊, 1-13 (2024) <https://doi.org/10.1109/TITS.2024.3454354>。会议名称: IEEE 智能交通系统汇刊。访问时间: 2024年10月11日
- [35] Towers, M., Kwiatkowski, A., Terry, J., Balis, J.U., De Cola, G., Deleu, T., Goulão, M., Kallinteris, A., Krimmel, M., KG, A., Perez-Vicente, R., Pierreé, A., Schulhoff, S., Tai, J.J., Tan, H., Younis, O.G.: Gymnasium: 强化学习环境的标准界面。arXiv. arXiv: 2407.17032 [cs] (2024) 。 <http://arxiv.org/abs/2407.17032> 访问时间: 2024-08-27
- [36] Kim, S.-G., Lee, E., Hong, I.-P., Yook, J.-G.: 无人机传感器模块有意电磁干扰及实验研究综述。传感器 **22**(6), 2384 (2022) <https://doi.org/10.3390/s22062384> 。数量: 6 出版商: 多学科数字出版研究所。访问时间: 2023年7月27日
- [37] Fujimoto, S., Hoof, H., Meger, D.: 解决 Actor-Critic 方法中的函数逼近错误。arXiv. arXiv: 1802.09477 [cs, 统计] (2018) 。 <http://arxiv.org/abs/1802.09477> 访问时间: 2024-02-18
- [38] Schulman, J., Wolski, F., Dhariwal, P., Radford, A., Klimov, O.: 近端策略优化算法。arXiv. arXiv: 1707.06347 [cs] (2017) 。 <http://arxiv.org/abs/1707.06347> 访问时间: 2022 年 11 月 3 日
- [39] Hochreiter, S., Schmidhuber, J.: 长短期记忆。神经计算 **9**(8), 1735–1780 (1997) <https://doi.org/10.1162/neco.1997.9.8.1735> 。访问时间: 2024年3月28日
- [40] Hafner, D., Pasukonis, J., Ba, J., Lillicrap, T.: 通过世界模型掌握不同领域。arXiv. arXiv:2301.04104 [cs, stat] (2023) 。 <http://arxiv.org/abs/2301.04104> 访问时间: 2023-12-06
- [41] Raffin, A., Hill, A., Gleave, A., Kanervisto, A., Ernestus, M., Dormann, N.: 稳定基线 3: 可靠的强化学习实现。机器学习研究杂志 **22**(268), 1–8 (2021) 。访问时间: 2024年10月9日