

陆地移动机器人无地图导航的并行分布式深度强化学习

维克多·A·基奇¹、阿利森·H·科林²、朱尼尔·科斯塔·德·赫苏斯²、加布里埃尔·V·海斯勒³、希亚戈·雅各布斯⁴、贾尔·A·博特加¹、安德烈·L. da S. Kelbouscas⁴、Akihisa Ohya¹、里卡多·B·格兰多^{2,4}、保罗·L·J·小德鲁斯 (Drews-Jr)²、丹尼尔 F. T. 加马拉 (Daniel F. T. Gamarra)³

¹ 筑波大学智能机器人实验室, (victorkich98@gmail.com) * 通讯作者 ² 里奥格兰德联邦大学, ³ 圣玛丽亚联邦大学, ⁴ 乌拉圭理工大学

摘要：本文介绍了新型深度强化学习 (Deep-RL) 技术，该技术使用并行分布式行动者-批评者网络来导航地面移动机器人。我们的方法使用激光测距、相对距离和与目标的角度来引导机器人。我们在 Gazebo 模拟器中训练代理并将其部署在真实场景中。结果表明，并行分布式 Deep-RL 算法可以增强决策能力，并且在导航和空间泛化方面优于非分布式和基于行为的方法。

关键词：并行分布式深度强化学习、陆地移动机器人、无地图导航

1. 简介

深度强化学习 (Deep-RL) 在控制离散和连续系统的工程和机器人领域显示出巨大的潜力[1]。最初应用于稳定的环境[2]，由于环境相互作用，它的复杂性随着地面移动机器人等非固定机器人的增加而增加。

为了解决这个问题，开发了专注于动作离散化的新深度强化学习技术[3]，在各种移动机器人的无地图导航中取得了成功[4]、[5]、[6]。分布式深度强化学习方法为有限模拟环境中的训练时间问题提供了有前景的解决方案 [7]。然而，地面移动机器人在复杂环境中的自主导航仍然具有挑战性。

我们提出了两种使用并行分布式技术的新深度强化学习方法：并行分布式确定性强化学习 (PDDRL) 和并行分布式随机强化学习 (PDSRL)，结合优先内存重放以增强复杂场景中的导航。如图 1 所示，我们的方法使用 24 维测距结果以及到目标的相对距离和角度。多个智能体的同时学习提高了模拟和现实场景中的性能。我们使用 Turtlebot3 Burger 机器人在四个日益复杂的场景中进行广泛的评估，包括用于空间泛化测试的额外真实场景。

这项工作的贡献包括：

- 两种新的分布式深度强化学习方法，使用简单的基于范围的传感架构来改进面向目标的无地图导航。
- 通过模拟到真实的评估来证明我们的方法的可行性，解决不精确和延迟等挑战。
- 有证据表明，具有优先体验重放的随机演员-评论家技术优于非




图 1：左图：Turtlebot3 Burger 在现实世界的障碍场景中导航。右图：我们提出的 PDDRL 和 PDSRL 方法的输入和输出结构。

分布式技术和经典算法，标志着首次使用并行分布式深度强化学习方法对地面移动机器人无地图导航进行广泛的模拟到真实评估。¹²

2. 相关作品

传统的 Deep-RL 模型将奖励作为单个值，但 Belle mare *et al.* [8] 提出将其建模为概率分布。Duan *et al.* [9] 将这个想法扩展到 Soft Actor-Critic (SAC) 算法的新实现中，这启发了我们的方法。

分布式深度强化学习是为了加速训练而引入的，涉及到跨多个处理器的分布式计算[10]。Mnih *et al.* [11] 使用异步 actor-critic 方法，而 Horgan *et al.* 开发了 Ape-X 方法，它将 actor 与学习器解耦 [10]。Barth-Maron *et al.* [7] 通过深度确定性策略梯度 (DDPG) 算法进一步改进了这一点。

Tai *et al.* [12] 展示了 Deep-RL 在移动机器人中的应用，激发了无地图导航的进步

¹<https://youtu.be/cOVoiJwLUA>

²<https://github.com/victorkich/Parallel-Turtle-DRL>

地面机器人的门控[3]。Jesus *et al.* [4] 探索了无需并行网络的无地图导航中的确定性和随机方法。

我们的工作引入了用于地面移动机器人无地图导航的并行深度强化学习方法，通过模拟到真实的评估来解决更复杂的场景。与传统的基于行为的算法 (BBA) [13] 以及使用经典和优先内存重放的 DDPG 和 SAC 并行版本相比，我们提出了 PDDRL (确定性) 和 PDSRL (随机) 方法。

3. 方法论

在本节中，我们将介绍 Deep-RL 的核心概念，包括确定性方法和随机方法的详细信息。此外，我们还展示了模拟和真实场景，解决了奖励系统和网络架构等具体问题。

3.1 深度强化学习

标准强化学习的目标是最大化折扣奖励总和的期望。状态-动作价值函数是一个数学模型，描述从状态 s 采取动作 a ，然后根据策略 π 采取行动时的预期回报[14]。这个函数，称为

$$Q_{\pi}(s, a) = \mathbb{E} \left[\sum_{t=0}^{\infty} \gamma^t r(s_t, a_t) \right], \quad (1)$$

通常用于评估策略的质量。

在每个时间步，网络都会预测当前状态的行为并生成时间差 (TD) 误差信号。贝尔曼操作员

$$(T_{\pi}Q)(s, a) = r(s, a) + \gamma \mathbb{E}[Q(s', \pi(s')) | s, a] \quad (2)$$

可以最小化这个 TD 误差，其期望是相对于下一个状态 s' 计算的。

这项工作采用了两个不同的神经网络，即演员和评论家，来评估 TD 误差。TD 误差在单独的目标策略和价值网络下进行评估，其中网络具有不同的参数 (θ', ω') 来稳定学习。批评者网络生成动作的 Q 值，而行动者网络的输出是代表所选动作的真实值。

3.2 并行分布确定性强化学习

DDPG 架构由 [15] 提出并在 D4PG [7] 中扩展，是连续观察空间中移动机器人的 Deep-RL 应用的基石 [16]。它采用了一个 actor-critic 框架，利用近似函数来学习连续空间中的策略。

DDPG 和 D4PG 之间的主要区别在于后者结合了分布式 Bellman 算子，这对于优化过程至关重要。该运算符定义如下：

$$(T_{\pi}Z)(s, a) = r(s, a) + \gamma \mathbb{E}[Z(s', \pi(s')) | s, a], \quad (3)$$

其中 $Q_{\pi}(s, a) = \mathbb{E} Z_{\pi}(s, a)$ 和 Z_{π} 返回一个分布变量，特别是分类分布。

在 D4PG 框架中，分类分布对批评者网络的输出进行建模，该网络预测预定义奖励箱的概率向量，每个奖励箱对应一系列潜在奖励值。这种分布允许网络估计预期回报的完整概率分布，而不是单个预期值，捕获可能结果的可变性：

$$\text{Categorical}(Z_{\pi}(s, a)) = [p_1, p_2, \dots, p_k], \quad (4)$$

其中 p_i 是返回落入第 i 个 bin 的概率， k 是 bin 的数量。批评家的训练包括最小化预测分布和目标分布之间的差异，通过更好地表示动态环境中的不确定性来增强政策的稳健性。

此外，D4PG 引入了 N 步返回的概念来估计时间差 (TD) 误差，表示为：

$$(T_{\pi}^N Q)(s, a) = r(s, a) + \mathbb{E} \left[\sum_{n=1}^{N-1} \gamma^n r(s_n, a_n) + \gamma^N Q(s_N, \pi(s_N)) | s, a \right]. \quad (5)$$

在我们的研究中，我们开发了一种基于 D4PG 的称为 PDDRL 的方法，结合了 N 步返回的扩展和建模为分类分布的批评值函数 [8]。确定性策略用 μ 表示，而噪声动作作用 μ' 表示，其中噪声过程涉及：

$$\mu' = \mu(s_t) + \mathcal{N}, \quad (6)$$

$\mathcal{N}$ 遵循 Ornstein-Uhlenbeck 过程 [17]。

鉴于原始 D4PG 研究报告的实验结果不一致 [7]，我们的研究导致我们开发了两种变体：PDDRL (利用经典重放内存) 和 PDDRL-P (采用优先重放内存) [18]。

最后，需要建立目标网络以增强学习稳定性。该网络是演员和评论家网络的复制品，但使用“软”更新。目标网络的权重 θ' 根据因子 τ 逐渐调整，如下式所示：

$$\theta' = \tau \theta + (1 - \tau) \theta'. \quad (7)$$

3.3 并行分布随机强化学习

SAC 架构 [19] 被提出作为 DDPG 等确定性行动者批评方法的随机对应物，采用近似函数来学习连续动作空间中的策略。SAC 引入了通过熵加法增强的 Bellman 算子，有助于探索和策略优化：

$$(T_{\pi}Q)(s, a) = r(s, a) + \gamma \mathbb{E}[Q(s', a') - \alpha \log \pi(a' | s') | s, a]. \quad (8)$$




图 2：并行 Deep-RL 训练过程结构。

为了促进强有力的探索，SAC 强调最大化政策的奖励和熵，从而促进行动多样性并阻止过早的政策收敛。该算法为产生相似 Q 值的操作分配相同的概率，并减轻由于不确定操作而导致 Q 函数近似的失败风险。

在此基础上，DSAC [20] 将 SAC 的最大熵框架与 DDPG 的分布式方法合并，从而产生了混合 Bellman 算子：

$$(T_{\pi}Z)(s, a) = r(s, a) + \gamma [Z(s', a') - \alpha \log \pi(a'|s') | s, a], \quad (9)$$

它集成了随机和分布组件，进一步描述为：

$$Z_{\pi}(s, a) = \sum_{t=0}^{\infty} [r(s, a) + \gamma - \alpha \log \pi(a_{t+1}|s_{t+1}) | s, a]. \quad (10)$$

在我们的研究中，新提出的 PDSRL 方法建立在 DSAC 的基础上，结合了 N 步返回和软更新的策略性使用（先前在 PDDRL 下的 3.2 节中详细介绍的功能），以提高预测准确性和稳定性。

我们实现了两种变体，使用经典重放存储器的 PDSRL 和具有优先重放存储器的 PDSRL-P，两者都具有 100000 步大小的重放存储器，以确保所有 Deep-RL 方法的一致性。

3.4 网络结构

我们工作中的所有方法都采用具有 26 个输入和两个输出的神经网络。输入包括激光雷达的 24 个测距结果，以及与目标的相对位置和相对角度。传感器样本范围从 0° 到 360° ，并以 15° 等间隔。输入角度用于引导车辆朝向目标并增强学习过程，而目标距离则鼓励网络将其最小化。同时，输出是能够控制车辆的线速度和角速度。作为与 Deep-RL 方法的比较，我们采用了传统的 BBA 技术，它使用硬编码的导航程序。值得注意的是，为了公平比较，BBA 使用与其他方法相同数量的传感器距离信息。

所有方法中使用的神经网络都具有三个隐藏的全连接层，有 256 个神经元




图 3：模拟和真实设置。

每个。这些层通过 ReLU 激活连接。动作范围在 -1 和 1 之间，参与者网络的激活函数是双曲正切函数 ($Tanh$)。线速度的输出在 -0.12 和 0.15 米之间缩放，而角速度的输出在 -0.1 m/s 和 0.1 m/s 之间缩放。在这两种方法中，批评者网络预测当前状态的 Q 值，而行动者网络预测当前状态。在并行方法的训练阶段，使用四名智能体进行训练，并使用一名智能体进行评估。训练过程如图2所示。

3.5 奖励功能

为了促进学习，有必要建立一个奖励制度，鼓励代理的良好行为并惩罚不良行为。该系统是根据经验评估获得的经验知识设计的。本次工作实施的奖励制度如下：

$$r(s_t, a_t) = \begin{cases} r_{arr} & \text{if } d_t < c_d \\ r_{coll} & \text{if } \min_x < c_o \\ r_{idle} & \text{if } \min_x \geq c_o \text{ and } d_t \geq c_d \end{cases} \quad (11)$$

定义了一个简单的奖励函数，仅提供三种类型的奖励：一种是成功完成任务的奖励，另一种是未能完成任务的奖励，如果前两者都没有发生，则最后一种奖励。成功代理奖励200元




图 4：每个场景中所有并行方法的每个训练步骤中代理奖励的移动平均值。场景按照从左到右、从上到下的顺序组织：1、2、3 和 4。




图 5: 通过在每个模拟场景中进行 100 次导航试验来评估每种并行方法的行为。这些线条说明了特工采取的路径，每个特工有 25 次尝试捕获每个目标的机会。




图 6: BBA 方法在模拟场景和真实场景中分别经过 100 次和 12 次试验进行评估。线条代表特工的路径，每个目标有 25 次（模拟）和 3 次（真实）尝试。

在距离目标 0.25 米的 c_d 米内成功到达目标。如果智能体与障碍物碰撞或达到场景的极限，则会给出 -20 的负奖励 r_{coll} 。当距离传感器读数小于距离 c_o （设置为 0.12 米）时，检测到碰撞。如果代理的激光雷达距离大于 c_o 并且目标距离大于 c_d ，则奖励 r_{idle} 为 0。此功能可以让您重点关注 Deep-RL 方法本身、它们的异同，而不是场景。

4. 实验

在本节中，我们将对我们提出的方法进行实验评估。这些实验旨在评估这些方法在模拟和现实环境中的性能。我们描述了用于训练和测试的模拟和真实场景的设置，然后对实验结果进行了详细分析。

4.1 模拟与真实场景

机器人和场景的模拟使用 Gazebo Simulator。机器人和代理之间的连接是使用机器人操作系统（ROS）建立的。为了分发代理，多个实例

Gazebo 模拟器是并行创建的，并将获取的数据发布到重播缓冲区。这里选择的机器人是 TurtleBot3 Burger 版本。使用的真实和模拟的 Turtlebot3 Burger 如图 3 所示。

本研究采用了四种模拟场景。第一个场景代表机器人移动的可导航区域，墙壁是可能导致机器人碰撞的唯一障碍。如果与墙壁或任何障碍物发生碰撞，则会对该动作发出负奖励，并终止当前剧集。第二种场景有四个固定的圆柱形障碍物，每个障碍物的半径为 25 厘米。第三和第四个场景的建立是为了为机器人创造更具挑战性的路径来达到最终目标。第三种场景包括一个“U”形物体，它为代理提供了两条可能的成本相等的轨迹，其中障碍物在中间形成了一个死胡同。第四种情况是不对称的并且更复杂，需要智能代理制定更好的策略来避免碰撞。图 3 中标注了真实场景和模拟场景。

通过模拟训练方法后，我们在真实场景中评估了我们的方法。使用 OpenCV 进行图像处理获得了真实场景中的一些必要数据。所有四个真实场景都类似于模拟场景，但它们的几何形状并不相同。每一个的差异在视觉上都更加明显——

表 1.: 所有方法在四种不同场景中超过 100 次（模拟）和 12 次（真实）导航试验的精度。

Scenario	BBA	DDPG	SAC	DDPG-P	SAC-P	PDDRL	PDSRL	PDDRL-P	PDSRL-P
First Sim.	100%	100%	100%	100%	100%	100%	100%	100%	100%
Second Sim.	62%	100%	0.0%	85%	64%	100%	100%	100%	100%
Third Sim.	75%	74%	0.0%	75%	0.0%	100%	100%	70%	100%
Fourth Sim.	73%	81%	25%	92%	0.0%	83%	98%	76%	100%
First Real	100%	100%	100%	100%	100%	100%	100%	100%	100%
Second Real	83.3%	100%	0.0%	100%	41.6%	100%	91.6%	100%	100%
Third Real	75%	100%	0.0%	100%	0.0%	100%	100%	0.0%	100%
Fourth Real	75%	66.6%	25%	100%	25%	25%	75%	75%	100%

第 4 节中规定。

4.2 实验结果

我们评估了模拟和现实场景中所有方法的导航能力和空间概括。训练阶段结束后，第一个场景包含 3 0000 步，其他场景包含 200000 步，我们分析了奖励的移动平均值（图 4）。结果表明，尽管起步较慢，但随机分布方法在所有情况下都优于其他方法。DDPG 的奖励方式与顶级方法类似。每种方法均使用预先确定的目标坐标进行了 100 多次评估。

表 1 显示了模拟实验的结果。无花果。图 5 和图 6 说明了 Deep-RL 和经典方法的行为。在场景 1 中，全部达到了 100% 的准确率。在更复杂的场景中，分布式算法保持 100% 的准确性，而其他算法则有所不同。DDPG 与分布式算法相匹配。

在场景 3 中，分布式方法的性能优于其他方法，但 PDDRL-P 除外，其准确度为 70%。这个问题在文献中是已知的，其中优先内存可能会限制基于 D4PG 算法的确定性分布式代理的泛化能力。在场景 4 中，只有 PDSRL-P 方法捕获了所有点，其次是 PDSRL，准确率达到 98%。值得注意的是，DDPG-P 的准确率达到了 92%，超越了确定性分布算法。

图 5 显示 PDSRL 和 PDSRL-P 具有更平滑的轨迹。DDPG 在场景 3 中表现出反复碰撞的不稳定性。优先级减少了场景 4 中的碰撞，但不稳定仍然存在。真实环境实验使用与模拟类似的目标点。图 7 显示了所有真实场景中的轨迹。PDSRL-P 和 DDPG-P 在真实环境中实现了 100% 的准确率。在场景 3 和 4 中，PDDRL 和 PDDRL-P 之间的性能差异非常显著。实际场景会引入延迟，从而影响性能。

表 2: 在顶级进近的额外场景中 12 次导航试验的精度和距离指标。

Algorithm	Precision (%)	Crashes (%)
DDPG	58.3%	41.6%
DDPG-P	100%	0.0%
PDDRL	100%	0.0%
PDSRL	75%	8.3%
PDSRL-P	100%	0.0%

我们提出了一种新颖的场景，其中场景 3 中的预训练模型在看不见的环境中进行评估。结果如图 7 和表 2 所示。DDPG 的崩溃率很高，而 PDSRL 最大限度地减少了崩溃，但并不总能获得回报。DDPG-P、PDDRL 和 PDSRL-P 实现了 100% 的准确率，表现出强大的空间泛化能力。

我们的广泛验证表明，所提出的方法在所有场景中都表现良好，包括新颖的场景。深度强化学习方法在现实世界的挑战中优于传统算法。优先版本取得了最高的成功率，特别是 PDSRL-P。在新场景中的评估证实了这些方法的学习能力和空间泛化能力。

5. 结论

这项工作介绍了地面移动机器人执行无地图导航的新颖深度强化学习（Deep-RL）技术，展示了它们的模拟学习能力和现实世界实施的潜力。结果强调，并行分布式深度强化学习方法可以有效解决复杂的现实世界机器人问题，而没有优先记忆重放的非基于学习和非分布式方法无法解决这些问题。

参考

- [1] T. P. Lillicrap, J. J. Hunt, A. Pritzel, N. Heess, T. Erez, Y. Tassa, D. Silver 和 D. Wierstra, “深度强化学习的连续控制”，参见 *ICLR*. PMLR, 2016. [2] S. Gu, T. Lillicrap, I. Sutskever 和 S. Levine, “基于模型加速的连续深度 q 学习”，*ICML*, 2016 年，第 2829-2838 页。[3] Y. Zhu, R. Mottaghi, E. Kolve, J. J. Lim, A. Gupta, L. Fei-Fei 和 A. Farhadi, “使用深度强化学习在室内场景中实现目标驱动的视觉导航”，参见 *IEEE ICRA*. IEEE, 2017 年，第 3357–3364 页。[4] J. C. de Jesus, V. A. Kich, A. H. Kolli ng, R. B. Grando, M. A. d. S. L. Cuadros 和 D. F. T. Gamarra, “移动机器人导航的软演员评论家”，*Journal of Intelligent & Robotic Systems*, 卷。102, 没有。2, 第 1-11 页, 2021 年。




图 7: (上) 通过在每个真实场景中进行 12 次导航试验来评估每种并行方法的行为。这些线条说明了代理所采取的路径, 每个代理都有 3 次尝试捕获每个目标的机会。(下) 在更真实的场景中评估的最佳分类并行方法的行为。按以下顺序组织: DDPG、DDPG-P、PDDRL、PDSRL 和 PDSRL-P。

[5] R. B. Grando, J. C. de Jesus, V. A. Kich, A. H. Kolling, N. P. Bortoluzzi, P. M. Pinheiro, A. A. Neto and P. L. Drews, “具有中等过渡的混合空中水下飞行器无地图导航的深度强化学习”, 参见 *IEEE ICRA*。IEEE, 2021 年, 第 1088–1094 页。[6] R. B. Grando, J. C. de Jesus, V. A. Kich, A. H. Kolling and P. L. J. Drews-Jr, “无人机无地图 3D 导航的双批评深度强化学习”, *Journal of Intelligent & Robotic Systems*, 卷。104, 没有。2, 第 1-14 页, 2022 年。[7] G. Barth-Maron, M. W. Hoffman, D. Budden, W. Dabney, D. Horgan, D. Tb, A. Muldal, N. Heess 和 T. Lillicrap, “分布式分布确定性策略梯度”, *ICLR*, 2018 年。[8] M. G. Bellemare, W. Dabney 和 R. Munos, “强化学习的分布视角”, *ICML*。PMLR, 2017 年, 第 449–458 页。[9] J. Duan, Y. guan, S.E. Li, Y. Ren, Q. Sun 和 B. Cheng, “分布式软演员批评家: 用于解决价值估计错误的非策略强化学习”, *IEEE Transactions on Neural Networks and Learning Systems (TNNLS)*, 2021。[10] D. Horgan, J. Quan, D. Budden, G. Barth-Maron, M. Hessel, H. van Hasselt 和 D. Silver, “Dis-致敬优先体验重播,” 在 *ICLR* 中。PMLR, 2018。[11] V. Mnih, A. P. Badia, M. Mirza, A. Graves, T. Lillicrap, T. Harley, D. Silver 和 K. Kavukcuoglu, “深度强化学习的异步方法”, 第 *ICML* 卷。48.纽约, 纽约

美国: PMLR, 2016 年 6 月 20-22 日, 第 1928-1937 页。[12] L. Tai, G. Paolo 和 M. Liu, “虚拟到真实的深度强化学习: 用于无地图导航的移动机器人的连续控制”, 参见 *IEEE/RSJ IROS*。IEEE, 2017 年, 第 31-36 页。[13] V. J. Lumelsky 和 A. A. Stepanov, “点移动自动机在任意形状的未知障碍物中移动的路径规划策略”, *Algo-rithmica*, 卷。2, 没有。1, 第 403–430 页, 1987 年 11 月。[14] R. S. Sutton 和 A. G. Barto, *Reinforcement learning: An introduction*。麻省理工学院出版社, 2018 年。[15] D. Silver, G. Lever, N. Heess, T. Degris, D. Wierstra 和 M. Riedmiller, “确定性策略梯度算法”, *ICML*。PMLR, 2014 年, 第 387-395 页。[16] L. Tai 和 M. Liu, “通过移动机器人的深度强化学习进行认知探索”, 2016。[17] G. E. Uhlenbeck 和 L. S. Ornstein, “论布朗运动理论”, *Physical review*, 卷。36, 没有。5, p. 823, 1930。[18] T. Schaul, J. Quan, I. Antonoglou 和 D. Silver, “优先体验重放”, *ICLR*。PMLR, 2016。[19] T. Haarnoja, A. Zhou, K. Hartikainen, G. Tucker, S. Ha, J. Tan, V. Kumar, H. Zhu, A. Gupta, P. Abbeel *et al.*, “软演员批评算法和应用”, 2018 年。[20] X. Ma, L. Xia, Z. Zhou, J. Yang 和 Q. Zhao, “Dsac: 风险敏感强化学习的分布式软演员批评家”, 2020 年。